2. NEIZRAZITA LOGIKA

U sklopu teorije neizrazitih skupova, postavljene 1965. godine [22], uveden je i koncept neizrazite logike, s kojim je omogućeno modeliranje semantičkih neodređenosti govornog jezika. Iako je početni razvoj ukazivao na potencijalnu primjenu u društvenim znanostima, područje pune afirmacije neizrazite logike postala je tehnika, u kojoj se koristi u širokom rasponu industrijskih i znanstvenih primjena. Danas su najznačajnija područja tehničke primjene neizrazite logike: automatska regulacija, analiza podataka, te sustavi za nadzor i dijagnostiku.

Opis prve praktične primjene neizrazite logike objavljen je relativno davno [23], kada je neizrazita logika primjenjena u regulaciji grijanja i protoka pare u laboratorijskom parnom postrojenju. Prva industrijska realizacija zabilježena je u procesu proizvodnje cementa [24], a nagli porast zanimanja za neizrazitu logiku i intenziviranje istraživanja počinje prije desetak godina, nakon uspješnih primjena u japanskim proizvodima široke potrošnje. Ekspanziju radova u području, u posljednjem desetljeću, dobro ilustrira broj naslova koji u sebi sadrže riječ "fuzzy" objavljenih u publikacijama koje pokriva baza INSPEC (Information Services for the Physics and Engineering Communities): u razdoblju 1970-1980 objavljeno je 566, 1980-1990 objavljeno je 2361, a u razdoblju 1990-1999 čak 22612 radova.

Neizrazita logika osigurava formalnu metodologiju za prikazivanje, manipulaciju i implementaciju ljudskog (ekspertnog) znanja o problemu regulacije procesa [25]. To je jedan od glavnih razloga što je većina radova i primjena neizrazite logike povezana s područjem automatske regulacije. Zamjena za iskusnog operatera, moto je svih primjena neizrazite logike u regulaciji procesa za koje, najčešće zbog teško izvedivog matematičkog modela, nisu postojala adekvatna konvencionalna rješenja. Osim procesa za čije je upravljanje bilo nužno ekspertno znanje, realizirane su i brojne primjene neizrazite logike u sustavima s poznatim matematičkim modelom, kod kojih je problem regulacije već bio više ili manje kvalitetno riješen korištenjem konvencionalnih koncepata. Kao glavni, premda često i osporavani razlozi primjene neizrazite logike u takvim sustavima najčešće se navode: veća robusnost i lakša sinteza regulatora. U nekim je slučajevima korištenje neizrazite logike motivirano i razlozima koji nisu samo tehnički. Neizrazita logika predstavlja novu metodologiju i njen izbor osigurava orginalnost aplikacije, a nije zanemariv niti propagandni utjecaj koju riječ "fuzzy" može imati na potencijalne kupce proizvoda. Iscrpan pregled primjena neizrazite logike u posljednjem desetljeću dan je u [11-14].

Ovo poglavlje podijeljeno je u četiri cjeline. U prvom dijelu se definiraju osnovni pojmovi neizrazite logike. U drugom dijelu su ukratko prikazani glavni načini primjene neizrazite logike u regulaciji i vođenju procesa. Treći dio opisuje glavne metode i postupke koji se koriste za određivanje strukture i parametara neizrazitih modela. U zaključnim razmatranja predočeni su stavovi najistaknutijih zagovornika i protivnika primjene neizrazite logike u regulacijskim sustavima.

2.1 NEIZRAZITA LOGIKA - OSNOVNI POJMOVI

U prikazu su iz puno šireg konteksta izvučeni i opisani samo oni pojmovi koji ilustriraju osnovnu ideju koncepta neizrazite logike i koji su relevantni za primjenu u sustavima automatske regulacije.

2.1.1 Neizraziti skup i funkcija pripadnosti

U tradicionalnoj (ili klasičnoj) teoriji skupova, koju je utemeljio njemački matematičar G. Cantor (1845.-1918.), skup predstavlja kolekciju objekata koji dijele neko zajedničko svojstvo [26, 27]. Definicija skupa je intuitivna, jer pojmovi *skup*, *kolekcija* ili *klasa* predstavljaju sinonime, jednako kao i pojmovi *objekt*, *član* ili *element*.

Pripadnost objekta "klasičnom" skupu egzaktno je određena: ili je objekt unutar skupa ili je izvan njega. Ako se pripadnost objekta skupu želi izraziti funkcijski, tada funkcija pripadnosti objekta x skupu A, $\mu_A(x)$ ima samo dvije vrijednosti i definirana je s:

$$\mu_A(x) = \begin{cases} 1, \text{ za } x \in A \\ 0, \text{ za } x \notin A \end{cases}$$

Skupovi klasične teorije često se nazivaju izraziti.

U nekim podjelama objekata na skupove stroga definicija pripadnosti nije prikladna, jer koji put nije moguće odrediti zadovoljavajuću izrazitu granicu između objekata. Kao tipičan primjer često se navodi problem matematičkog opisa ljudske percepcije temperature okoline, gdje se po iznosu vrlo bliske numeričke vrijednosti mogu naći u različitim skupovima. Tako npr. osoba upitana za klasifikaciju temperatura zraka, u skup *vruće* može smjestiti sve temperature veće od 30 °C, dok će intuitivno vrlo bliska vrijednost od 29,9 °C pripadati drugom skupu (npr. *toplo*). Simbolički zapis izrazitog skupa *vruće* preko funkcije pripadnosti bio bi sljedeći:

$$\mu_{vruće}(x) = \begin{cases} 1, \text{ za } x \geq 30 \text{ °C} \\ 0, \text{ za } x < 30 \text{ °C} \end{cases}$$

Za razliku od tradicionalnog pristupa, teorija neizrazith skupova dopušta djelomičnu ili stupnjevanu pripadnost elementa skupu, a funkcijske vrijednosti funkcije pripadnosti nalaze se unutar intervala [0,1]. Pri tome vrijednost 0 označava da je objekt potpuno izvan skupa, 1 da je potpuno unutar skupa, a bilo koja vrijednost između označava djelomičnu pripadnost. Tako bi se neizraziti skup *vruće* mogao definirati s npr.:

$$\mu_{vruće}(x) = \begin{cases} 1, & \text{za } x > 34\ ^\circ C \\ (x-26)/8, & \text{za } 26\ ^\circ C \leq x \leq 34\ ^\circ C \\ 0, & \text{za } x < 26\ ^\circ C \end{cases}$$

Ovakva definicija znatno je bliža načinu na koji čovjek doživljava i u govoru interpretira osjet temperature okoline. Tako bi prosječan promatrač, naravno u određenoj klimatskoj zoni, označio temperaturu od 22 °C s nije vruće, 28 °C s malo je vruće, 33 °C s prilično vruće, a 40 °C s jako vruće. Razlika između funkcija pripadnosti neizrazitog i izrazitog skupa *vruće* ilustrirana je na slici 2.1.

U literaturi se prednosti koje neizraziti skupovi pružaju u interpretaciji neodređenosti govornog jezika često ilustriraju i primjerom grupiranja artikala prema njihovoj cijeni (npr. *skupo* računalo) ili primjerom klasificiranja percepcije starosti čovjeka (pripadnost skupu *mlad* ili*star*).

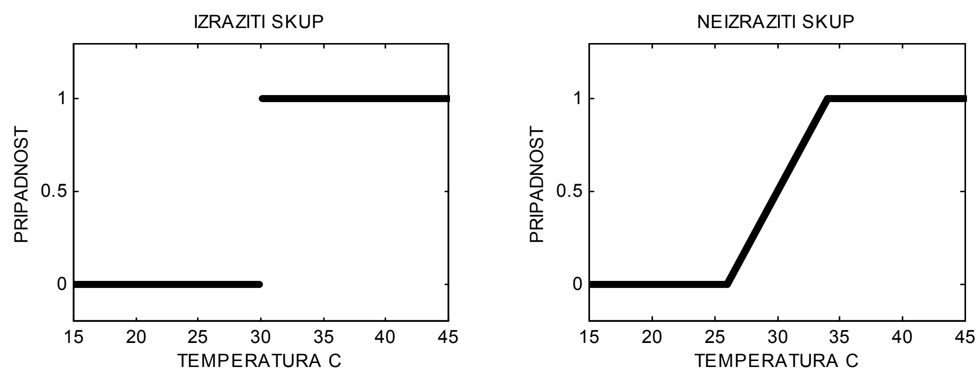

Slika 2.1 Funkcije pripadnosti izrazitog i neizrazitog skupa *vruće*

U okvirima teorije neizrazitih skupova pojmovi *vruće*, *svježe*, *star*, *skup* ili *visok* predstavljaju neizrazite skupove koji određuju *jezične varijable* ili u užem smislu vrijednosti jezičnih varijabli. Na primjer, jezična varijabla *cijena* može imati četiri vrijednosti (*vrlo visoka*, *visoka*, *niska* i *vrlo niska*), odnosno četiri odgovarajuća neizrazita skupa.

Neizraziti skup određen je funkcijom pripadnosti. Način zadavanja funkcije pripadnosti najviše ovisi o karakteru objekata ili podataka koji se grupiraju (brojivi ili nebrojivi, diskretni ili kontinuirani), odnosno tipu domene (područja definicije) nad kojim se zadaju.

Ako su domene kontinuirane i brojive (npr. podskup ili čitav skup realnih brojeva *R*) tada je najčešći oblik zadavanja funkcije pripadnosti preko funkcijskog izraza, kao npr.:

$$\mu_A(x) = 1 / (1+ (x - a)^2)$$

koji predstavlja neizraziti skup *A* s maksimumom funkcije pripadnosti u točki $x = a$.

Za zadavanje neizrazitih skupova nad diskretnim domenama koriste se drukčiji oblici, kod kojih se svakom objektu ili podatku pridružuje stupanj pripadnosti. Tako se npr. skup *C* = "dio grada poželjan za stanovanje" može zadati s:

C = {(Vrhovec, 0.4), (Pantovčak, 0.9), (Šalata,0.8)}

pri čemu pridruženi stupnjevi odražavaju preferenciju ispitane osobe.

Operacije nad neizrazitim skupovima

Unija, presjek i komplement osnovne su teoretske operacije definirane nad klasičnim skupovima. Te su operacije ujedno i podloga operacijama disjunkcije, konjukcije i negacije u klasičnoj (binarnoj) logici. U tablici 2.1 osnovne operacije nad izrazitim skupovima prikazane su korištenjem analogije između operatora $\cup$, $\cap$, ^{C} i logičkih operatora ILI ($\vee$), I ($\wedge$), NE ($\neg$). Tako npr. četvrti redak tablice označava sljedeće: ako objekt *x* pripada skupu *A* ($\mu_A(x) = 1$) i ne pripada skupu B ($\mu_B(x) = 0$), tada objekt x ne pripada skupu $A \cap B$ ($\mu_{A\cap B}(x) = 0$), pripada skupu $A \cup B$ ($\mu_{A\cup B}(x) = 1$), i ne pripada komplementu skupa A ($\mu_{A^C}(x) = 0$)

A	B	A ∧ B	A ∨ B	¬ A
0	0	0	0	1
0	1	0	1	1
1	0	0	1	0
1	1	1	1	0

Tablica 2.1 Osnovne operacije nad izrazitim skupovima

Na sličan način na koji klasična teorija skupova predstavlja temelj klasične logike, teorija neizrazitih skupova temelj je neizrazite logike. Veza je uspostavljena preko definicije osnovnih operacija nad skupovima i njihovih logičkih ekvivalenata. Proširenje skupa funkcijskih vrijednosti funkcije pripadnosti sa samo dvije ({0,1}) u klasičnoj, na čitav interval ([0,1]) u neizrazitoj teoriji omogućilo je i znatno veći broj definicija osnovnih operacija nad neizrazitim skupovima.

Općenita definicija operacija unije i presjeka nad neizrazitim skupovima izvedena je preko trokutnih normi i konormi. Trokutna norma (*t*-norma) je binarna operacija na intervalu $[0,1]$, $T : [0,1]^2 \rightarrow [0,1]$ koja ima sljedeća svojstva:

$$T(x,y) = T(y,x) \quad \text{komutativnost} \tag{2.1}$$

$$T(T(x,y),z) = T(x,T(y,z)) \quad \text{asocijativnost} \tag{2.2}$$

$$T(x,y) \leq T(z,w) \text{ ako je } x \leq z \text{ i } y \leq w \quad \text{monotonost} \tag{2.3}$$

te zadovoljava rubni uvjet

$$T(x,1) = x \tag{2.4}$$

Ako je T t – norma, tada je odgovarajuća trokutna konorma $S : [0,1]^2 \rightarrow [0,1]$ zadana s:

$$S(x,y) = 1 - T(1-x,1-y) \tag{2.5}$$

U literaturi se [28, 29] navodi desetak karakterističnih parova T i S normi, dok u primjenama dominiraju sljedeće [30]:

Minimum T_M, maximum S_M

$$T_M(x,y) = \min(x,y), \qquad S_M(x,y) = \max(x,y) \tag{2.6}$$

Algebarski produkt T_P, algebarska suma S_P

$$T_P(x,y) = x \cdot y, \qquad S_P(x,y) = x + y - x \cdot y \tag{2.7}$$

Lukasiewicz t - norma T_L (ograničeni produkt), ograničena suma S_L

$$T_L(x,y) = \max(x + y - 1, 0) \quad S_L(x,y) = \min(x + y, 1) \tag{2.8}$$

Ako su date *t*-norma T, *t*-konorma S, te neizraziti skupovi A iB na domeni X onda su funkcije pripadnosti presjeka $A \cap B$, unije $A \cup B$ i komplementa A^c zadane s:

$$\mu_{A \cap B}(x) = T(\mu_A(x), \mu_B(x)) \tag{2.9}$$

$$\mu_{A \cup B}(x) = S(\mu_A(x), \mu_B(x)) \tag{2.10}$$

$$\mu_{A^c}(x) = 1 - \mu_A(x) \tag{2.11}$$

Navedenu definiciju komplementa neizrazitog skupa uveo je Zadeh [31], a dvije različite parametarske definicije predložili su Sugeno [32] i Yager [33].

Na slici 2.2 ilustrirane su osnovne operacije nad neizrazitim skupovima primjenom T_M norme i S_M konorme te Zadehove definicije komplementa.

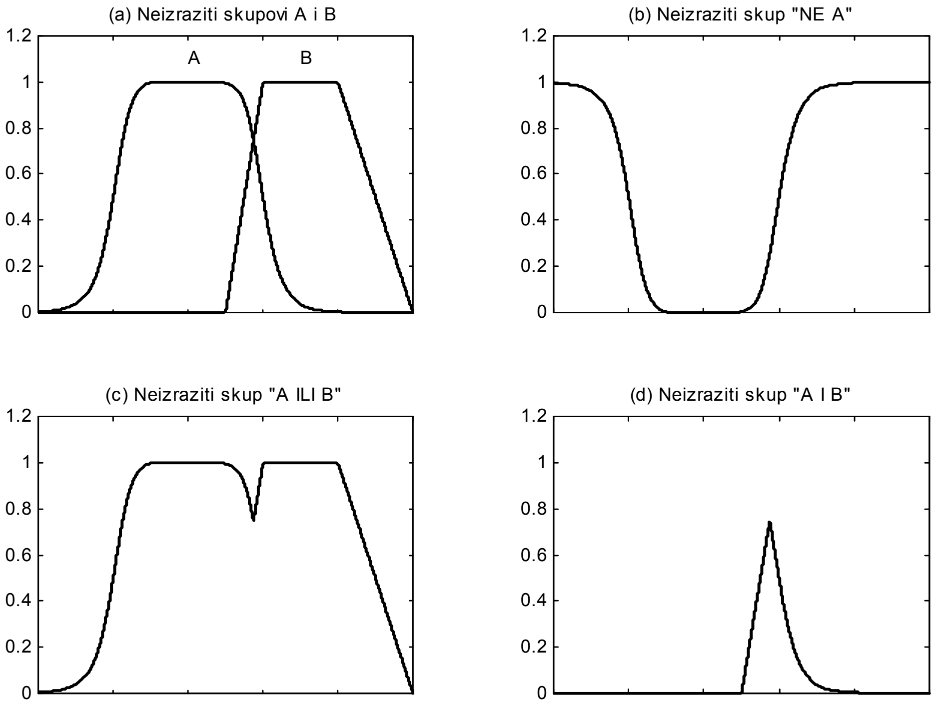

Slika 2.2 Osnovne operacije nad neizrazitim skupovima

2.1.2 Neizrazita pravila i neizrazite relacije

U formiranju kvantitativnih modela ljudskog razmišljanja (koje je izraženo riječima i rečenicama govornog jezika) polazi se od *neizrazite propozicije.* Općeniti oblik neizrazite propozicije dat je s *"x je A",* gdje je *A* jezična vrijednost zadana s neizrazitim skupom nad domenom varijable *x*. Neizrazita propozicija uspoređuje varijablu *x* i skup *A*, odnosno određuje stupanj pripadnosti varijable *x* neizrazitom skupu *A*. U općem slučaju varijabla *x* može biti izrazita (numerička) ili neizrazita (neki neizraziti skup).

Za povezivanje propozicija koriste se riječi (veznici) *I*, *ILI*, te *AKO – ONDA* koje se kvantificiraju preko T i S normi. Kombinacijom propozicija i veznika nastaje *neizrazito pravilo* koje u općem slučaju ima oblik:

AKO x je A I y je B ONDA z je C

i gdje *"x je A I y je B"* predstavlja *premisu* ili *uvjet* , a *"z je C" zaključak* ili *posljedicu* pravila. Slična pravila koriste se u svakodnevnom govoru za opisivanje različitih pojava, kao npr:

- ako je brzina velika i nadolazeći zavoj je oštar, onda je kočenje naglo,
- ako je cijena dionice niska i počinje rasti, onda kupuj puno,
- ako se temperatura pare smanjuje onda povećaj protok goriva i zraka

Za opis odabranog procesa, sustava ili događaja obično je potreban veći broj pravila pa se često govori i o skupu odnosno *bazi* neizrazitih pravila.

Za matematičku interpretaciju neizrazitih pravila koriste se *neizrazite relacije* koje definiraju kvantitativnu vezu između varijabli premise i varijabli zaključka. Pojam neizrazite relacije ilustriran je, bez gubitka općenitosti, na neizrazitom pravilu koje ima jednu propoziciju u premisi i jednu u zaključku.

Neka X i Y predstavljaju domene varijabli x i y nad kojima su definirani neizraziti skupovi A i B i neka je dato neizrazito pravilo *AKO x je A ONDA y je B* (što je ekvivalentno simboličkom zapisu $A \to B$, odnosno značenju *A implicira B).* Tada je s

$$R = A \to B = \{((x,y),\mu_R(x,y)) \mid (x,y) \in X \times Y\} \tag{2.12}$$

zadana binarna neizrazita relacija R, koja svakom paru (x,y) iz *Kartezijevog produkta* $X \times Y$ pridružuje vrijednost $\mu_R(x,y)$. Pri tome je $\mu_R(x,y)$ trodimenzijska funkcija pripadnosti binarne neizrazite relacije R zadana s

$$\mu_R(x,y) = f(\mu_A(x),\mu_B(y)) \tag{2.13}$$

i gdje je f *neizrazita funkcija implikacije* koja stupnjeve pripadnosti x u A i y u B transformira u stupnjeve pripadnosti parova (x,y) u relaciji $A \to B$. U općem slučaju neizrazita relacija predstavlja matematički zapis baze neizrazitih pravila. Tada je funkcijom f pored implikacije pojedinih obuhvaćeno i akumuliranje pravila, a funkcija f je uobičajeno definirana kao kombinacija T norme i S konorme (za implikaciju odnosno akumulaciju pravila).

Također, potrebno je definirati način na koji se na temelju poznatih činjenica i zadane neizrazite relacije određuju zaključci. Tzv. proces *neizrazitog zaključivanja* može se promatrati kao opći slučaj matematičke operacije u kojoj se određuje funkcijska slika na temelju zadane relacije (funkcije) i poznatog originala.

Ilustracija izrazite i slične neizrazite relacija data je na slici 2.3. Na lijevoj strani prikazana je izrazita relacija kod koje funkcija $y = f(x) = -0.5x^2+8x$ definira odnos varijabli x i y. Kod neizrazite relacije, prikazane na desnoj strani, taj odnos određen je bojom točke u XY ravnini. U izrazitom slučaju, uz poznatu ulaznu varijablu $x = 4$, i poznatu funkcijsku ovisnost može se zaključiti (izračunati) da je $y = f(4) = 24$.

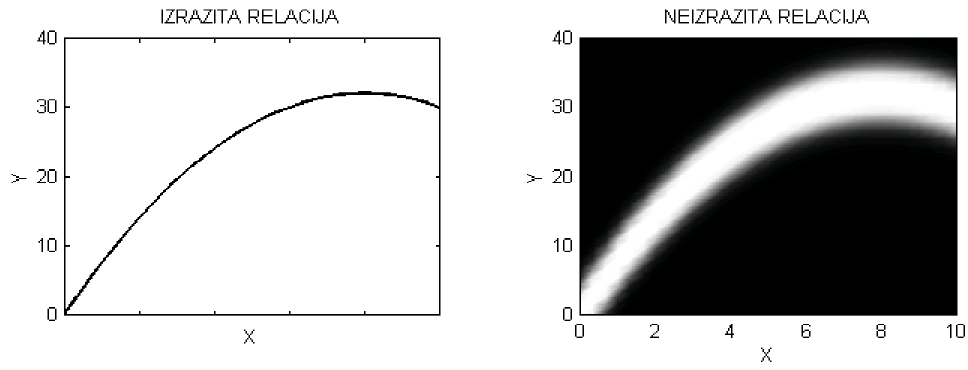

Slika 2.3. Izrazita i neizrazita relacija

U neizrazitom slučaju, u kojem su i funkcijski argumenti i funkcije neizraziti skupovi postupak određivanja izlazne vrijednosti (zaključivanje) provodi se prema tzv. "*compositional rule of inference*" (CRI) [31]. Geometrijska interpretacija postupka ilustrirana je na slici 2.4 [35], dok je opis postupka dat u nastavku.

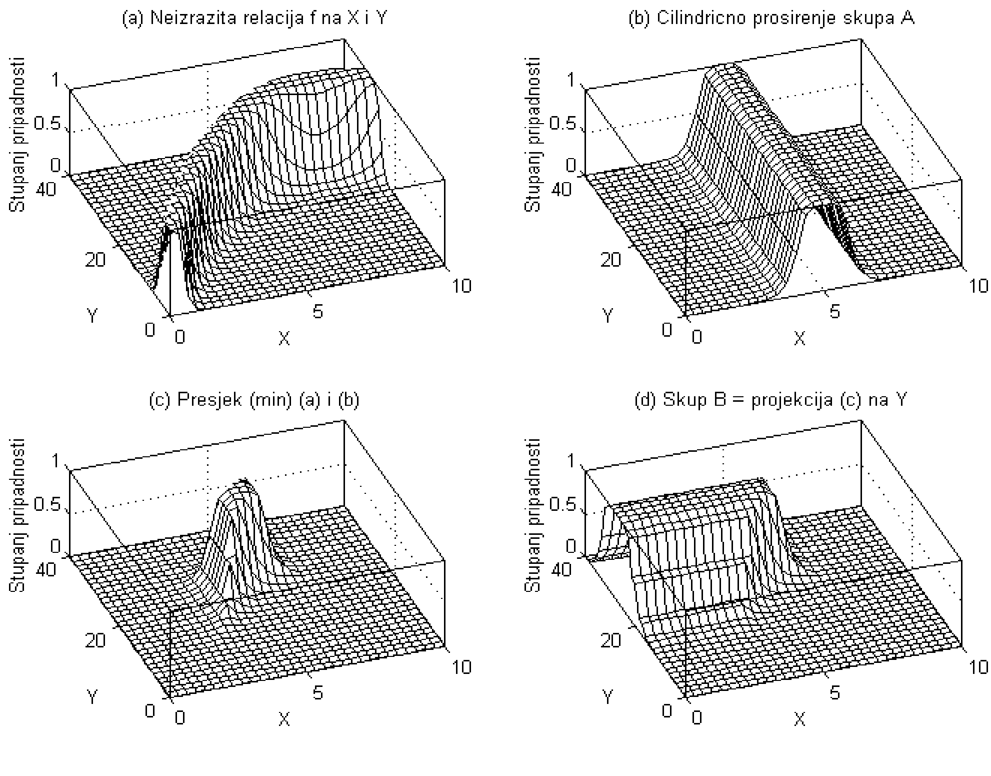

Slika 2.4. Geometrijska interpretacija postupka neizrazitog zaključivanja prema "compositional rule of inference" (CRI)

Neizrazita relacija *f* zadana je trodimenzijskom funkcijom pripadnosti nad ravninom razapetom skupovima (intervalima) *X* i *Y* (sl. 2.4 (a)). Prvi korak u postupku zaključivanja, odnosno određivanja izlaznog neizrazitog skupa *B* je cilindrično proširenje skupa A nad čitavu ravninu $X \times Y$ (sl. 2.4 (b)). Sljedeći korak, prikazan na sl. 2.4 (c), je određivanje presjeka funkcija pripadnosti cilindričnog proširenja $c(A)$ i neizrazite relacije f. Projekcija presječne funkcije na ravninu $x = 0$ predstavlja izlazni neizraziti skup B (sl. 2.4 (d)). Formalni zapis prethodno ilustriranog postupka neizrazitog zaključivanja dat je u obliku neizrazite relacijske jednadžbe $B = A \circ f$, gdje $\circ$ predstavlja operator kompozicije funkcija. Funkcija pripadnosti izlaznog skupa B određuje se prema sljedećim izrazima:

$$\mu_{c(A)}(x,y) = \mu_A(x) \qquad \text{cilindrično proširenje}$$

$$\mu_{c(A)\cap f}(x,y) = min\,[\mu_{c(A)}(x,y),\, \mu_f(x,y)] = min\,[\mu_A(x),\, \mu_f(x,y)] \qquad \text{presjek}$$

$$\mu_B(y) = max_x min\,[\mu_A(x),\, \mu_f(x,y)] \qquad \text{projekcija}$$

U operatoru projekcije max_x index x ističe način određivanja rezultantnog skupa. Svaka točka u skupu predstavlja najveću vrijednost presječnih funkcija pripadnosti u ravninama od $y = 0$ do $y = 40$ (ravnine paralelne s osi x i okomite na os y koje presjecaju skup $\mu_{c(A)\cap f}(x,y)$). Ako se operatore *max* i *min* promatraju samo kao prikaz logičkih operacija disjunkcije i konjukcije tada se funkcija $\mu_B(x)$ može izraziti i simbolički

$$\mu_B(x) = \vee_x[\mu_A(x) \wedge \mu_f(x,y)] \tag{2.14}$$

Postupak CRI omogućava poopćavanje procesa zaključivanja u smislu prelaska s dvovveličinske (klasične) na viševeličinsku (neizrazitu) logiku. U klasičnoj logici istinitost zaključka B određuje se na temelju istinitosti premise A i istinitosti implikacije $A \rightarrow B$. Zaključak može biti ili istinit ili lažan a postupak se simbolički zapisuje u obliku: $B = A \circ (A \rightarrow B)$. U neizrazitoj logici, koja je bliža načinu ljudskog razmišljanja, dopušta se parcijalna istinitost i premise i zaključka, a postupak zaključivanja zapisuje se u obliku: $B' = A' \circ (A \rightarrow B)$, gdje su A' i B' propozicije neznatno različite od definicijskih A i B. Kao intuitivna ilustracija postupka može poslužiti tipičan savjet turistima, izražen u obliku pravila:

AKO (KADA) si u Splitu, ONDA čini isto što i Splićani

Striktno tumačenje ove preporuke značilo bi da postaje primjenjiva tek s prolaskom pored ploče s oznakom grada. Međutim, oprezan turist uzet će je u obzir već u blizini Splita, npr. na Klisu. U navedenom primjeru oznaka A pridružena je premisi *"ako si u Splitu"*, a oznaka B zaključku *"čini isto što i Splićani"*. Oznaka A' imala bi značenje propozicije *"ako si blizu Splita"*, dok bi se zaključak B' mogao tumačiti kao *"čini više ili manje isto što i Splićani"*.

Primjenom koncepta neizrazitog skupa i pridruženog postupka neizrazitog zaključivanja (preko CRI) moguće je kvantificirati ideju približnog rasuđivanja (*engl. approximate reasoning*) koja je glavna značajka procesa ljudskog razmišljanja. Modeli s pomoću kojih se kvantificira postupak neizrazitog zaključivanja nazivaju se *neizraziti modeli* ili općenito *neizraziti sustavi*. Struktura i način realizacije neizrazitog sustava opisana je u nastavku.

2.1.3 Neizraziti sustavi

Neizraziti sustav je bilo koji statički ili dinamički sustav koji koristi neizrazitu logiku i pripadajući matematički okoliš (teoriju neizrazitih skupova, neizrazita pravila i neizrazito zaključivanje) [36]. Ova relativno široka definicija obuhvaća neizrazite sustave koji se primjenjuju u različitim područjima i za koje se mogu koristiti i drugi nazivi kao npr.: neizraziti ekspertni sustav (*engl. fuzzy expert system*), neizraziti regulator (*fuzzy logic controller*), neizraziti model (*fuzzy model*), sustav neizrazitih pravila (*fuzzy rule based system*), (*fuzzy associative memory*) [37].

Bez obzira na naziv ili područje primjene, neizraziti sustavi u osnovi sadrže tri komponente: bazu pravila, bazu podataka o funkcijama pripadnosti koje su zadane nad domenama ulaznih i izlaznih varijabli, te mehanizam zaključivanja. Neizraziti sustavi općenito su predviđeni za obradu neizrazitih ulaznih podataka (izraženih preko neizrazitog skupa). Izraziti ulazni podaci mogu se promatrati kao poseban oblik neizrazitog skupa (tzv. *singleton*) ili se, kao što je to slučaj u brojnim izvedbama, za transformaciju ulaznih podatka koristi poseban blok digitalno - neizrazite pretvorbe (engl. *fuzzification*). Ovisno o primjeni kao i odabranom tipu neizrazitog modela izlaz iz neizrazitog sustava može biti izrazita veličina ili neizraziti skup. U neke je sustave u svrhu dobivanja izrazite izlazne veličine potrebno ugraditi i četvrtu komponentu, blok neizrazito – digitalne pretvorbe (engl. *defuzzification*). Ilustracija neizrazitog sustava data je na slici 2.5. Crtkanom linijom omeđena je osnovna struktura u kojoj nije posebno istaknut blok digitalno – neizrazite pretvorbe. U prethodnom razmatranju, kao i u nastavku izlaganja, pretpostavljen je digitalni karakter ulaznih i izlaznih signala. Realizacije neizrazitih sustava u analognom okruženju su slične [38, 39] s obzirom na osnovnu ideju.

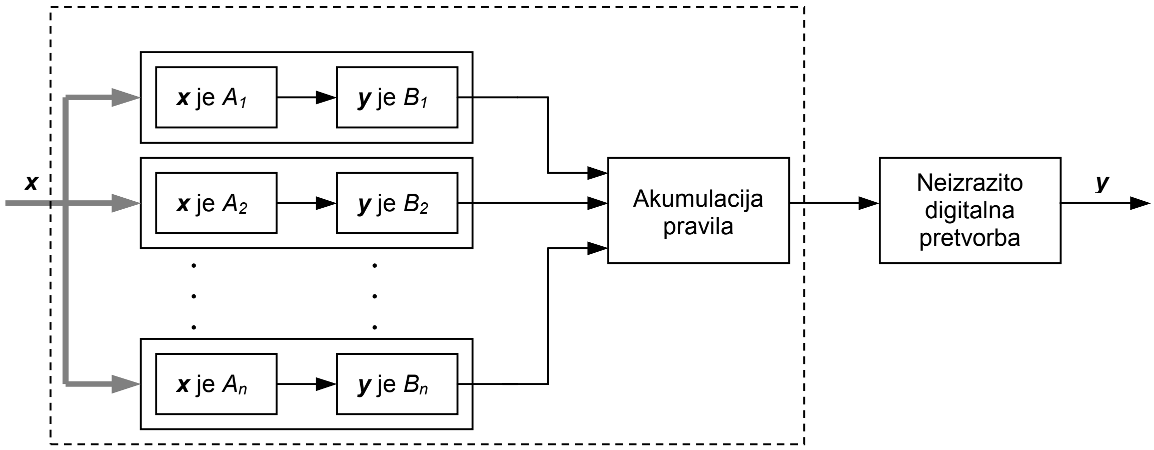

Slika 2.5. Shematski prikaz neizrazitog sustava

S obzirom na mehanizam zaključivanja neizraziti sustavi načelno se mogu podijeliti u dvije kategorije. Za razliku od relacijskog pristupa opisanog u prethodnom paragrafu (koji se često naziva i globalni) u praktičnim primjenama dominira postupak lokalnog zaključivanja. Razlog leži u memorijskim i procesorskim ograničenjima računala, osobito izraženim u vrijeme prvih primjena neizrazite logike. U postupku globalnog zaključivanja koristi se neizrazita relacija koja obuhvaća čitavu bazu pravila, a točnost relacije, pohranjene u memoriju računala izravno ovisi o gustoći diskretizacije domena ulaznih i izlaznih varijabli. Nasuprot tome, kod lokalnog zaključivanja izračunavaju se samo ona pravila koja su u promatranom trenutku relevantna s obzirom na vrijednost ulaznih varijabli. Kod lokalnog zaključivanja memorijski zahtjevi su niži jer se u memoriju računala spremaju samo parametri funkcija pripadnosti ulaznih i izlaznih varijabli. U nastavku opisani Mamdani i Sugeno neizraziti modeli predstavljaju najznačajnije i najčešće korištene modele lokalnog zaključivanja.

Mamdani model

Ovaj model korišten je u prvoj opisanoj primjeni neizrazite logike [23] za kvantificiranje jezičnih pravila kojima je iskusni operater opisao problem regulacije protoka i temperature pare u laboratorijskom parnom postrojenju. Struktura modela odnosno algoritam zaključivanja ilustrirana je s dva primjera. Prvi primjer je općenit i pretpostavalja neizraziti karakter ulaznih i izlaznih varijabli, dok je drugi primjer vrlo sličan praktičnim realizacijama u području regulacije procesa.

Primjer 2.1. Neka je dat neizraziti sustav s jednom ulaznom i jednom izlaznom varijablom, te tri pravila oblika

AKO $\boldsymbol{x}$ *je* A_i *ONDA* $\boldsymbol{y}$ *je* B_i, … i = 1, 2, 3

gdje $\boldsymbol{x}$ i $\boldsymbol{y}$ predstavljaju ulazne i izlazne varijable (općenito neizrazite) iz skupova X i Y, nad kojima su zadane particije A_i i B_i. Grafički prikaz funkcija pripadnosti, pravila neizrazitog sustava te ilustracija algoritma zaključivanja dati su na slici 2.6.

Neka je ulazna varijabla $\boldsymbol{x}$ definirana neizrazitim skupom A'. Jezična interpretacija skupa A' mogla bi biti '$\boldsymbol{x}$ *je približno 6*'. U algoritmu zaključivanja razlikuju se sljedeći koraci:

1. određivanje stupnja prekrivanja (ili stupnja istinitosti premise) β_i između ulaznog skupa i skupova u premisama neizrazitih pravila

$$\beta_i = \max_x \left[\mu_{A'}(x) \wedge \mu_{A_i}(x)\right] \quad \dots \; i = 1, 2, 3 \tag{2.15}$$

2. određivanje lokalnog izlaznog skupa

$$\mu_{B'_i}(y) = \beta_i \wedge \mu_{B_i}(y) \tag{2.16}$$

3. akumuliranje lokalnih skupova u jedinstveni neizraziti skup izlazne varijable.

$$\mu_{B'_i}(y) = \max_{1 \le i \le 3} \mu_{B'_i}(y) \tag{2.17}$$

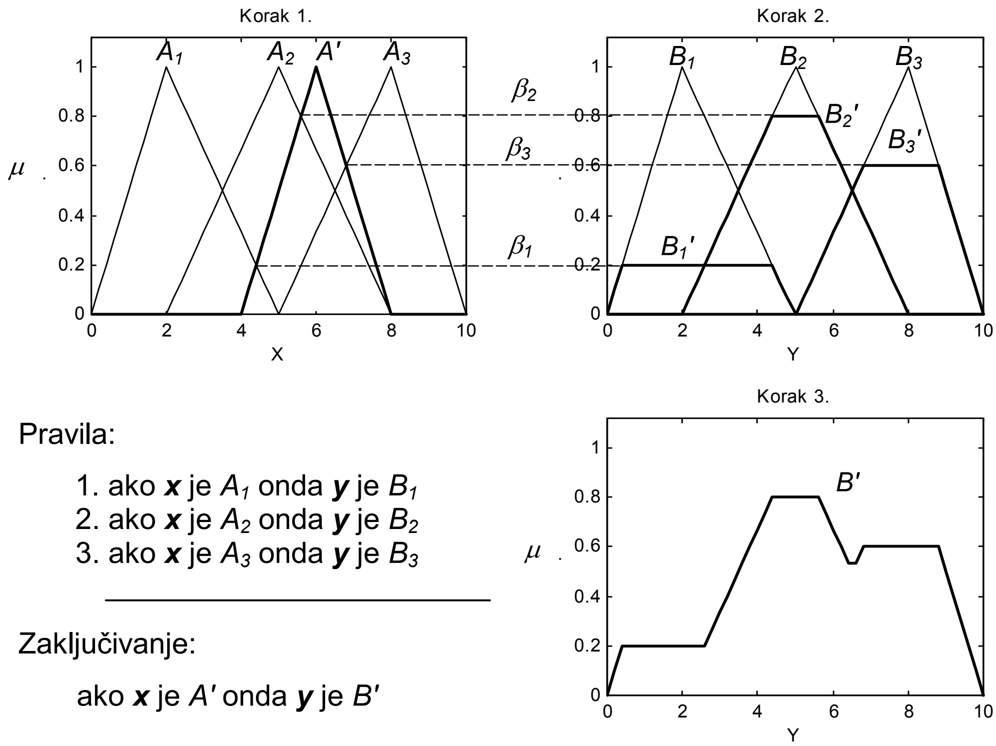

Slika 2.6 Algoritam neizrazitog zaključivanja prema Mamdaniu

Na ovom primjeru moguće je i grafički pokazati ekvivalentnosti postupaka lokalnog i globalnog zaključivanja. Ako je za zadanu bazu pravila i zadane particije A_i i B_i, neizrazita relacija μ_R određena s

$$\mu_R = \max_i \left[\min(\mu_{A_i}(x), \mu_{B_i}(x)) \right] \tag{2.17}$$

(tzv. max – min kompozicija odnosno kombinacija norme T_M za implikaciju i konorme S_M za akumulaciju), tada se primjenom CRI (dakle rješavanjem relacijske jednadžbe $B' = A' \circ (A_i \rightarrow B_i)$) na izlazu dobija izlazni skup identičan prikazanom na slici 2.6. Na slici 2.7 data je ilustracija postupka globalnog zaključivanja.

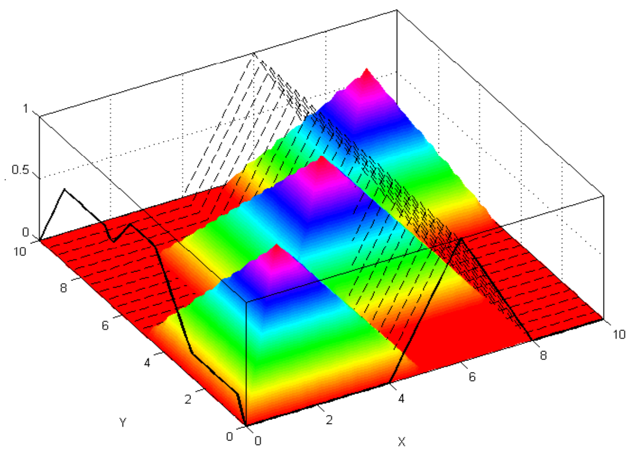

Slika 2.7. Globalno zaključivanje $B' = A' \circ (A_i \rightarrow B_i)$ prema CRI

Neizrazitu relaciju određuju tri piramide nad ravninom *XY* (boja označava stupanj pripadnosti neizrazitog para (x,y)). Crtkano je prikazano cilindrično proširenje ulaznog skupa A', a debljom linijom označen je izlazni skup B' (odnosno projekcija presjeka cilindričnog proširenja i neizrazite relacije na ravninu $x = 0$). Formalni matematički dokaz identičnosti lokalnog i globalnog zaključivanja za prethodno opisani primjer, s jednom ulaznom i jednom izlaznom varijablom dat je u prilogu 2.1.

U prethodnom primjeru ulazna varijabla u sustav je neizrazita, odnosno skup A' koji je zadan funkcijom pripadnosti nad domenom X. Ukoliko bi umjesto neizrazite vrijednosti '***x** je približno 6*' u sustav uvodili egzaktnu vrijednost '***x** = 6*' prvi korak u algoritmu zaključivanja bi se mogao pojednostavniti. Skup A' može se zadati kao *singleton* skup odnosno s: $\mu_{A'}(6) = 1$ i $\mu_{A'}(x) = 0$, $x \in X$ i $x \neq 6$. Tada je $\beta_i = \mu_{Ai}(6)$. Identična vrijednost dobila bi se i primjenom postupka digitalno – neizrazite pretvorbe (engl. *fuzzification*) u kojem se niti formalno ne definira neizraziti skup ulazne varijable A' nego se stupanj pripadnosti određuje izravno (dakle $\beta_i = \mu_{Ai}(6)$, ali bez primjene operatora *max* i $\wedge$).

Grafički prikaz globalnog postupka zaključivanja znatno je složeniji jer je već kod sustava koji imaju dvije ulazne i jednu izlaznu varijablu neizrazita relacija zadana u četverodimenzijskom prostoru.

U većini slučajeva neizraziti modeli opisuju sustave koji imaju više od jedne ulazne varijable. Primjer sustava s dvije ulazne i jednom izlaznom izrazitom varijablom opisan je u nastavku.

Primjer 2.2. Neizraziti regulator temperature i vlažnosti zraka u prostoriji upravlja brzinom vrtnje ventilatora. Ulazne varijable su temperatura T i vlažnost zraka H i nad čijim su domenama definirani neizraziti skupovi *hladan*, *topao*, *vruć*, odnosno *suh*, *umjeren*, *vlažan*. Brzina vrtnje ventilatora ω može biti *mala*, *srednja* ili *velika*. Raspodjela funkcija pripadnosti zajedno s tablicom upravljačkih pravila i ilustracijom postupka zaključivanja data je na slici 2.8.

Proces zaključivanja ilustriran je za trenutne izrazite vrijednosti signala temperature $T = T_i$ i vlažnosti $H = H_i$. Signal temperature T_i pripada, ili ako je definiran kao *singleton* presijeca sam skup *topao*, dok signal vlažnosti H_i pripada skupovima *suh* i *umjeren*. U formiranju izlaznog signala sudjeluju samo dva pravila, prikazana osjenčanim poljima u tablici na slici 2.8:

ako je zrak '*topao*' i '*suh*' onda je brzina ventilatora '*mala*'.

ako je zrak '*topao*' i '*umjeren*' onda je brzina ventilatora '*srednja*'.

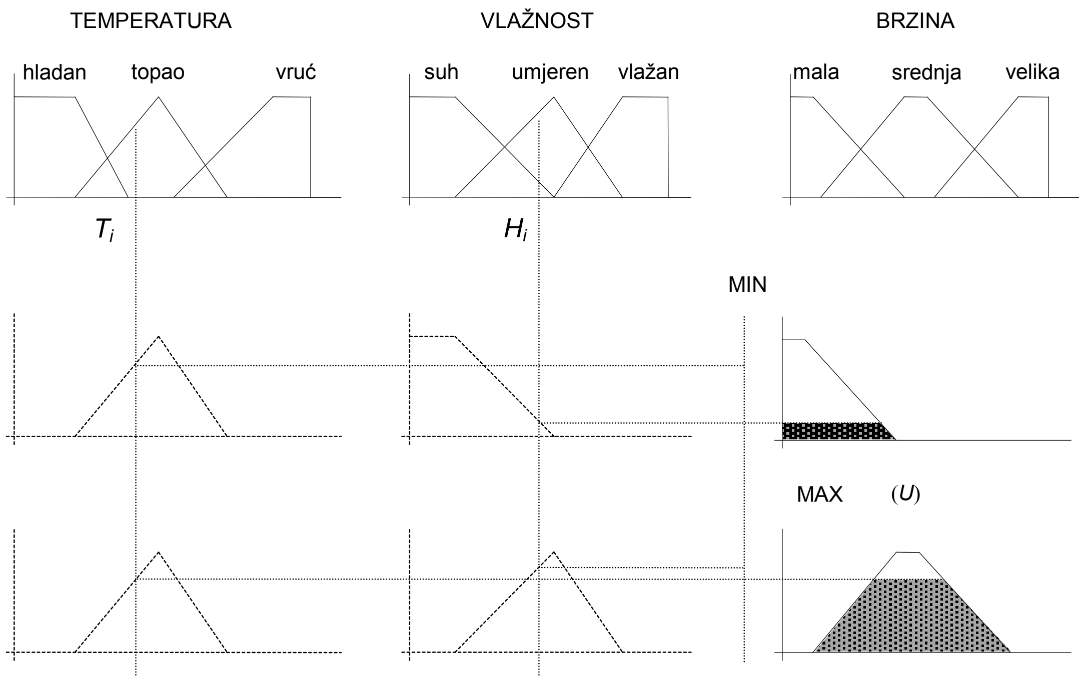

Pravila

H \ T	*HLADAN*	*TOPAO*	*VRUĆ*
SUH	MALA	MALA	SREDNJA
UMJEREN	MALA	SREDNJA	VELIKA
VLAŽAN	SREDNJA	VELIKA	VELIKA

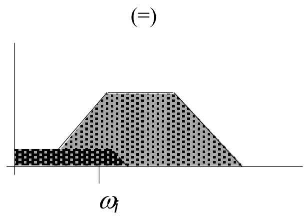

Slika 2.8. Neizraziti regulator stanja zraka u prostoriji, raspodjela funkcija pripadnosti, tablica upravljačkih pravila i ilustracija procesa zaključivanja

U usporedbi sa sustavom s jednim ulaznim signalom, opisanim u primjeru 2.1, algoritam zaključivanja razlikuje se samo u prvom koraku. Premisa upravljačkog pravila sadrži dvije propozicije povezane veznikom *I*. U primjeru je stupanj istinitosti premise β_i određen kao manji od dva stupnja pripadnosti ulaznih varijabli pripadnim skupova. Izborom manje vrijednosti zadovoljen je logički uvjet prema kojem istinitost zaključka ne može biti veća od istinitosti premise. U drugom koraku izlazni skup u zaključku svakog pravila odsijeca se do visine određene stupnjem istinitosti β_i . Rezultantni neizraziti skup formira se kao unija u prethodnom koraku formiranih odsječaka izlaznih skupova svih važećih pravila. Izlazna izrazita vrijednost brzine vrtnje ventilatora ω_i u primjeru je određena kao apscisa težišta nepravilnog geometrijskog lika kojim je predstavljen rezultantni izlazni skup.

U prethodnom opisu pojam odsijecanja izlaznog skupa predstavlja kolokvijalni naziv postupka implikacije, kod kojeg se za određivanje istinitosti zaključka koristi operator *min* (odnosno norma T_M). Osim T_M norme za implikaciju se često koristi i T_P norma.

Zbrajanje (akumulacija) odsječaka izlaznih skupova provedeno je korištenjem operatora max (norma S_M). Za akumulaciju se često koristi i operator ograničene sume (norma S_L).

Iako je u primjeru 2.2 operator *min* (odnosno norma T_M) korišten i za određivanje stupnja istinitosti premise (usporedba propozicija odnosno kvantifikacija veznika *I*), tu primjenu treba odvojeno promatrati od postupka implikacije. Naime, za konjunkciju se mogu koristiti i druge *T* norme, a općenito se u premisama mogu pojaviti i propozicije povezane veznicima *ILI* (za čiju bi se kvantifikaciju koristile *S* konorme).

Izborom operatora akumulacije i implikacije određen je i naziv kompozicije odnosno postupka zaključivanja. Tako je u primjerima 2.1 i 2.2. opisana max–min kompozicija koja se prema [28, 40] najčeće primjenjuje u regulacijskim sustavima. U algoritmima zaključivanja susreće se i max-prod kompozicija (odnosno kombinacija S_M i T_P norme) kod koje se stupanj istinitosti β_i premise određuje kao produkt stupnjeva prekrivanja svake propozicije u premisi, a neizraziti skup zaključka nastaje množenjem β_i i funkcije pripadnosti izvornog skupa. Max-min i max-prod kompozicije uklapaju se u osnovne teoretske postavke neizrazitog zaključivanja (u smislu dokazivanja ekvivalentnosti globalnog i lokalnog postupka, odnosno primjene CRI). Potrebno je spomenuti i sum-prod kompoziciju (kombinacija S_L i T_P normi) koja se ne uklapa u teoretske okvire, ali je pogodnija za praktične primjene jer je računski manje intezivna.

U brojnim primjenama neizrazite logike rezultantni izlazni skup se ne može koristii već je na izlazu, kao u primjeru 2.2, potrebno osigurati izrazitu (analognu ili digitalnu) vrijednost. Za određivanje izrazite vrijednosti koriste se različite metode neizrazito - izrazite pretvorbe (engl. *defuzzification*) [41, 42], a najpoznatije su:

– metoda težišta (engl. *Center of Gravity*) geometrijskog lika (tijela) definiranog rezultantnim neizrazitim skupom, može se koristiti i za skupove zadane u više dimenzija,
– metoda središta ukupne površine (engl. *Center of Area*), u kojoj su površine neizrazitog skupa lijevo i desno od izlazne veličine identične (alternativni naziv je i*Bisector of Area*),
– metoda središnje točke maksimuma (engl. *Mean of Maximum*), tj. srednja vrijednost apscisa točaka u kojima funkcija pripadnosti izlaznog neizrazitog skupa dostiže maksimum (slične su metode najmanje i najveće apscise, odnosno *Smallest and Largest of Maximum*).

Zbog dobrih interpolacijskih svojstava u primjenama prevladava metoda težišta. Metoda težišta u kombinaciji sa sum-prod kompozicijom pogodna je za formiranje linearnog neizrazitog modela što je ilustrirano u prilogu 2.2.

Metode neizrazito - izrazite pretvorbe računski su vrlo intezivne što predstavlja nedostatak u praktičnim primjenama. Opseg računanja može se značajno smanjiti ako se u zaključku koriste *singleton* izlazni skupovi ili izrazite funkcije.

Sugeno model

U usporedbi s prethodno opisanim Sugeno model (često nazvan i Takagi - Sugeno model [43]) razlikuje se u načinu definiranja zaključka. Umjesto neizrazite propozicije koristi se izrazita funkcija čiji su argumenti ulazne izrazite varijabe . Pravila Sugeno modela zadaju se u obliku:

AKO x je A_i I y je B_i ONDA je $z_i = f_i(x,y)$

gdje su A_i i B_i particije neizrazitih skupova zadane nad domenama ulaznih varijabli X i Y, a $f_i(x,y)$ izrazite funkcije zaključka. Funkcije f_i zadaju se polinomski, najčešće polinomom nultog ili prvog stupnja, a stupanj polinoma određuje naziv modela (pa se razlikuju Sugeno modeli nultog i prvog reda). Izlaz iz Sugeno modela uvijek je izrazit i određuje se interpolacijom zaključaka prema izrazu:

$$z = \frac{\sum_i \beta_i z_i}{\sum_i \beta_i} \tag{2.18}$$

gdje je β_i stupanj istinitosti premise pojedinog pravila, a i broj važećih pravila ili ukupan broj pravila neizrazitog sustava. Model nultog reda predstavlja poseban oblik Mamdani modela kod kojeg su izlazni skupovi diskretne vrijednosti. Funkcije u zaključcima pravila modela prvog reda mogu se promatrati i kao lokalne linearne aproksimacije nelinearnih funkcija zadanih u prostoru razapetom ulaznim varijablama. Ako postoji prekrivanje funkcija pripadnosti ulaznih varijabli prijelazi između lokalnih linearnih izlaznih funkcija su glatki, kao što je to slučaj sa sustavom prikazanim na slici 2.9.

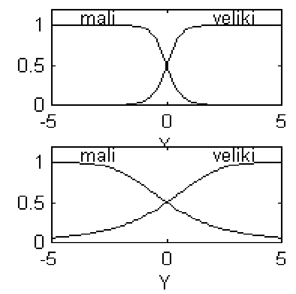

Pravila:

x	*y*	*z*
mali	mali	$-x+y+1$
mali	veliki	$-y+3$
veliki	mali	$-x+3$
veliki	veliki	$x+y+2$

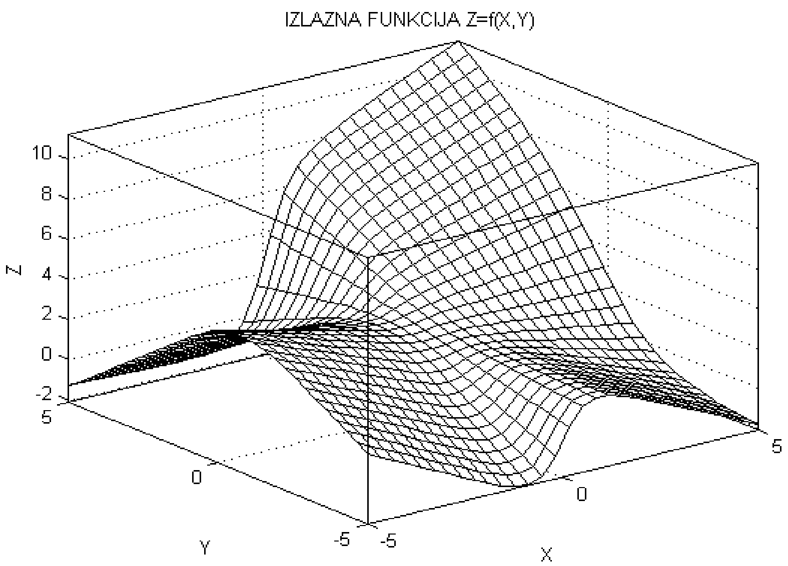

Slika 2.9. Sugeno model prvog reda s dvije ulazne varijable

Izlazna funkcija *Z* na slici 2.9 može predstavljati i upravljačku funkciju regulatora koji obrađuje dva ulazna signala čije trenutne vrijednosti određuju parametre regulatora. U ilustriranom primjeru razlikuju se četiri skupa parametara, a primjenom Sugeno modela ostvaren je tzv. *'bezudarni'* prijelaz s jednog skupa parametara na drugi. To je i glavni razlog česte primjene u regulacijskim sustavima gdje se koriste za vođenje parametara lokalnih konvencionalnih linearnih (PID) regulatora.

Međutim, osim stupnja prekrivanja, na karakter izlazne funkcije utječe i tip ulaznih funkcija pripadnosti, što je ilustrirano na slici 2.10. Sugeno model prvog reda s jednom ulaznom i jednom izlaznom varijablom zadan je s tri pravila:

AKO je x *mali* ONDA je $y = 3x + 2$
AKO je x *srednji* ONDA je $y = -2.5x + 30$
AKO je x *veliki* ONDA je $y = -0.01x + 5$

Na slici su u prvom stupcu date particije ulaznih neizrazitih skupova, a u drugom stupcu rezultantna izlazna funkcija. U primjeru (a) ulazna particija je izrazita a izlazna je prekinuta i po odsječcima linearna. U primjeru (b) ulazne funkcije pripadnosti su glatke i djelomično prekrivene, a izlazna funkcija je neprekinuta, glatka i po dijelovima približno linearna (dobro preklapanje s pravcima u pozadini). Primjer (c) pokazuje da izbor ulaznih funkcija pripadnosti u obliku trokuta značajno mijenja karakter izlazne funkcije i uvodi veliko ostupanje od lokalnih linearnih aproksimacija. Detaljnija analiza interpolacijskih svojstava Sugeno modela data je u [44].

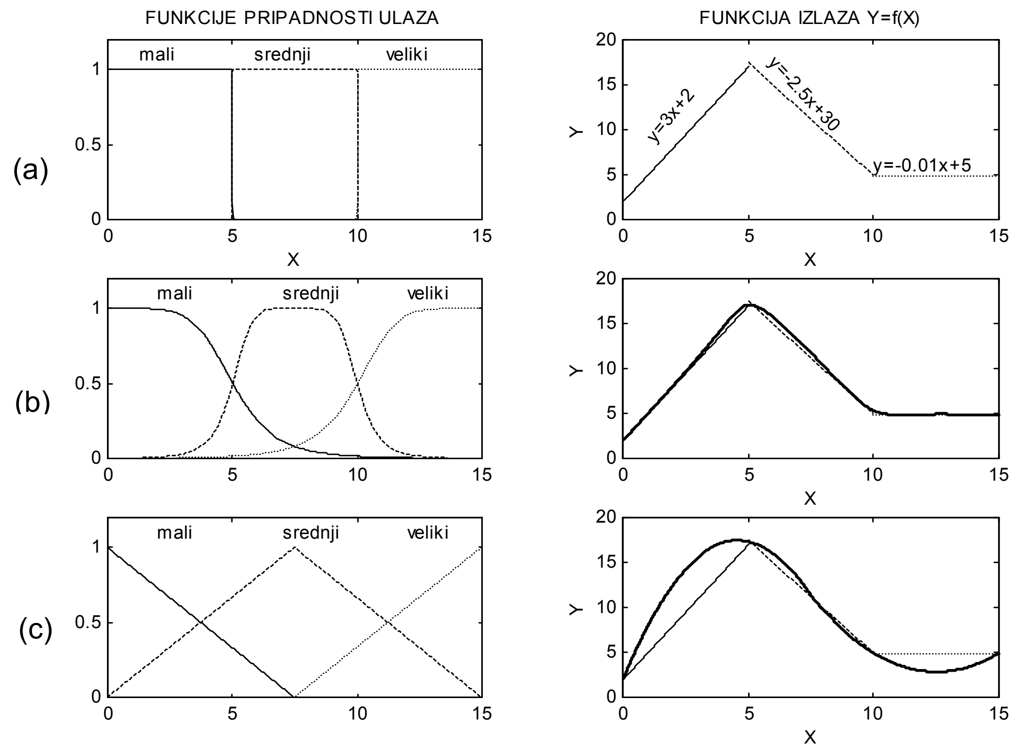

Slika 2.10 Utjecaj izbora ulazne funkcije pripadnosti na karakter izlazne funkcije Sugeno modela

Prethodno je spomenuto da su ulazne varijable u Sugeno model izrazite. Načelno je moguća, iako u dostupnim radovima nije pronađena, i obrada neizrazitih varijabli kod koje bi se neizrazite izlazne varijable određivale korištenjem tzv. principa proširenja (engl. *extension principle*, prema [45]).

Struktura Sugeno modela pogoduje primjeni algoritama identifikacije parametara sustava na temelju dostupnih ulaznih i izlaznih podataka, a modeliranje složenih procesa neizrazitim pravilima i funkcijama pripadnosti predstavlja jedno od glavnih područja takve primjene. Također, Sugeno modeli nultog reda mogu se koristiti i za fino ugađanje eventualno grube interpolacije jezičnih pravila i funkcija pripadnosti Mamdani modela.

U prvoj polovici devedesetih godina, u pozadini brojnih praktičnih primjena neizrazite logike bila je intuicija i iskustvo projektanata. To je otvorilo prostor teoretskim istraživanjima usmjerenim k traženju formalnih koncepata koji će omogućiti matematičko dokazivanje intuitivnih postavki. Jedan takav koncept, koji se temelji na relaciji jednakosti i kojim se dokazuje konzistentnost Mamdani modela s parcijalnim upravljačkim (ekspertnim) pravilima dat je u prilogu 2.3. (prema [46, 47]).

2.2 NEIZRAZITA LOGIKA U SUSTAVIMA REGULACIJE I VOĐENJA

Uspjeh neizrazite logike uglavnom je povezan s primjenama u sustavima regulacije i vođenja. Gruba podjela primjena može se napraviti ili prema načinu korištenja koncepta ili prema mjestu implementacije u sustavu. S obzirom na način korištenja neizrazite logike moguće je izdvojiti dvije kategorije sustava: sustave u kojima je neizrazita logika iskorištena za implementacija znanja operatera u automatizirani regulacijski algoritam i u kojima do izražaja dolazi izvorna ideja (tj. obrada jezičnih pravila i kvalitativnih informacija), te sustave kod kojih se neizrazita logika koristi za definiranje nelinearnog preslikavanja u prostoru ulaznih i izlaznih (izrazitih) varijabli. S druge strane, potencijalna mjesta primjene mogu se ilustrirati regulacijskim razinama u hijerarhijskoj strukturi složenog sustava regulacije i vođenja procesa. U takvim sustavima razlikuju se: podređena regulacijska razina (na kojoj se procesna mjerenja uspoređuju s referentnim veličinama a lokalni regulatori djeluju na izvršne organe u svrhu uklanjanja regulacijskih odstupanja), nadređena regulacijska razina (gdje se ovisno o statusu procesa definiraju referentne veličine podređenih regulacija) i razina vođenja procesa (ili razina optimizacije i koordinacije). Opće značajke regulacije na nižim razinama su brze reakcije i lokalno djelovanje. Na višim razinama općenito se izvode sporije akcije s djelovanjima koja su u mnogim slučajevima globalna. Osim sustava regulacije i vođenja, sustavi procesne automatizacije obuhvaćaju i sustave za nadzor i dijagnostiku pogrešaka, također mjesta potencijalne primjene neizrazite logike. U nastavku su, sukladno hijerarhijskoj podjeli i pojmovima uvedenim u [48], opisani karakteristični primjeri primjene.

2.2.1 Regulacija na lokalnoj (podređenoj) razini

Na lokalnoj regulacijskoj razini neizrazita logika najčešće se primjenjuje u obliku tzv. neizrazitog regulatora. U donjem dijelu slike 2.11. blok shemom prikazan je lokalni regulacijski krug u kojem se razlikuju blokovi procesa (*P*) i neizrazitog regulatora (*NR*), te izraziti signali regulacijskog odstupanja (*e*), izlaza iz procesa (*y*) i regulacijskog zahvata (*u*). Neizraziti regulator zadan je bazom pravila i funkcijama pripadnosti i u osnovi (preko postupaka izrazito – neizrazite pretvorbe, neizrazitog zaključivanja i neizrazito - izrazite pretvorbe) definira nelinearno statičko preslikavanje skupa ulaznih u skup izlaznih varijabli. Dinamičko ponašanje neizrazitog regulatora, koje je zahtijevano u mnogim primjenama, postiže se većim brojem ulaznih varijabli. U tom slučaju u regulatoru se koriste, pored trenutnih i prošle vrijednosti ulaznih i izlaznih signala (iz jednog ili više vremenskih koraka). Stoga pojam neizrazitog regulatora u širem smislu obuhvaća statičku upravljačku funkciju, proširenu sa statičkim pojačanjima ulaznih i izlaznih signala te blokove dinamičkih djelovanja s pomoću kojih se simuliraju kašnjenja, derivacijski ili integracijski članovi. Dinamička struktura PD neizrazitog regulatora prikazana je u gornjem dijelu slike 2.11.

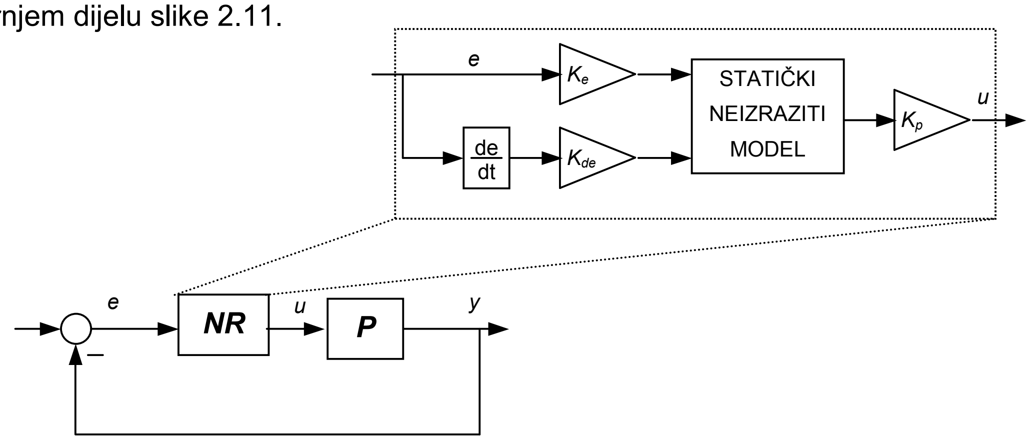

Slika 2.11. Neizraziti PD regulator u podređenom regulacijskom krugu

Odgovarajućim izborom funkcija pripadnosti, pravila ili operatora kompozicije moguće je realizirati i bilo koje linearno preslikavanje, pa i ona preslikavanja odnosno regulacijske funkcije koje su definirane linearnim PID regulatorima. Ilustracija statičkog neizrazitog modela s nelinearnom i linearnom regulacijskom funkcijom data je na slici 2.12. Dodatni ulazni signal je regulacijsko odstupanje (*de*). Neizrazita pravila koja odgovaraju Sugeno modelu nultog reda opisana su tablično i identična su za oba regulatora. Za konjukciju propozicija u premisama korišten je operator *prod*. Razlika između regulacijskih funkcija posljedica je samo razlike u tipu funkcija pripadnosti ulaznih varijabli.

(a)

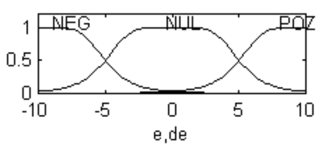

Pravila:

de \ e	NEG	NUL	POZ
NEG	-20	-10	0
NUL	-10	0	10
POZ	0	10	20

(b)

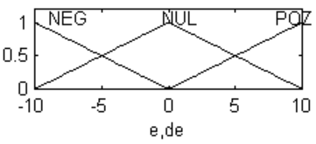

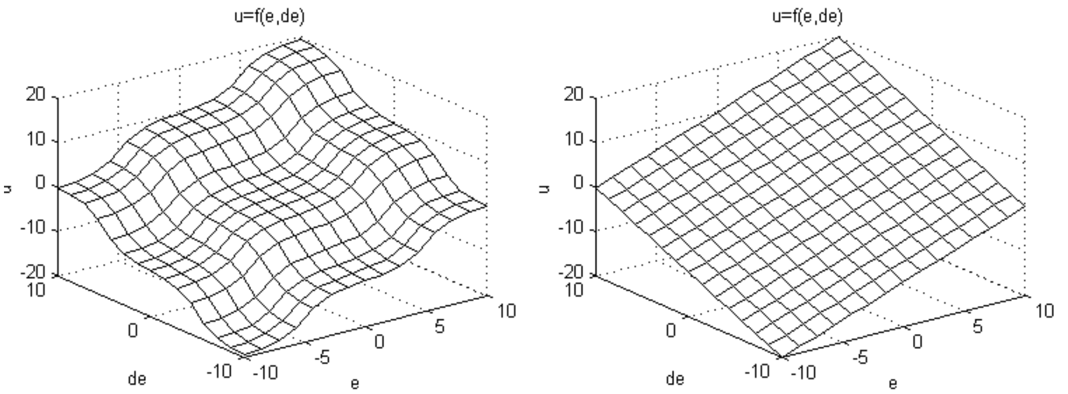

Slika 2.12 Nelinearni (a) i linearni (b) neizraziti regulator

Regulacijska funkcija linearnog neizrazitog regulatora (slika 2.12 (b)) identična je statičkoj regulacijskoj funkciji konvencionalnog PD regulatora zadanoj analitički s $u = 2e+2de$ (treba naglasiti sa samo dva parametra).

Usporedba s konvencionalnim PID regulatorima na lokalnoj razini tema je mnogih radova [49-53] koji na primjerima pokazuju prednosti neizrazitog koncepta, pri čemu se pored robusnosti (u uvjetima velikih poremećaja ili promjena parametara procesa) naglašava brza i razumljiva sinteza neizrazitog regulatora s pomoću jezičnih pravila.

U pogledu robusnosti, eventualne prednosti neizrazitog regulatora posljedica su prije svega nelinearne regulacijske funkcije i izraženije su kod usporedbi s izvornim oblikom linearnog PID regulatora, projektiranim na temelju linearnog modela procesa (koji po definiciji pretpostavljaju male poremećaje i male promjene parametara). Prednosti su manje ukoliko se konvencionalnom regulatoru dodaju neke od standrdnih funkcija suvremenih mikroprocesorskih regulatora koje omogućavaju jednostavno definiranje nelinearnih regulacijskih značajki (npr. funkcije vođenja parametara, mrtve zone, o smjeru ovisne regulacijske akcije) Također, na slikama 2.10 i 2.12, te u prilogu 2.2 pokazano je da ovisno o strukturi i parametrima neizrazitog modela regulacijska funkcija neizrazitog regulatora može biti i linearna, ili općenito više ili manje nelinearna što implicira veću ili manju robusnost. Stoga tvrdnju o većoj robusnosti treba preformulirati u blaži oblik: ukoliko su barem djelomično poznate varijacije parametara procesa neizraziti regulator (koji ima daleko veći broj parametara za ugađanje) je moguće projektirati tako da bude manje osjetljiv na te promjene, a s time i robusniji u usporedbi s linearnim regulatorom. Sukladno s prethodnom tvrdnjom primjena neizrazitog regulatora u regulaciji nelinearnih procesa opravdana je tek u slučaju ako se ne može postići zadovoljavajuća kvaliteta regulacije s PI i PID regulatorima i ako se iscrpe sva konvencionalna pravila ugađanja njihovih parametara [25, 54].

Široko područje potencijalnih primjena neizrazite logike, i to ne samo na lokalnoj regulacijskoj razini, su procesi kod kojih je teško definirati analitički model i koji se uglavnom mogu samo kvalitativno opisati. U regulaciji takvih procesa dominira znanje operatera, a karakteristični su za: industriju cementa, industriju stakla, obradu hrane, procese vulkanizacije, procese sušenja… Neizraziti regulator simulira regulacijsko ponašanje operatera i obično ima funkciju održavanja kvalitete proizvoda na propisanoj razini. Kvaliteta proizvoda je često puta određena neizrazitim parametrima (boja, hrapavost, homogenost, tvrdoća, i sl.), što upućuje na primjenu neizrazitog koncepta.

Akvizicija znanja operatera u obliku jezičnih pravila koristi se i u primjenama neizrazitog regulatora u vožnji automobila ili upravljanju kranom (smanjenje njihanja tereta). Premda se ovi primjeri načelno mogu opisati matematički, a problem regulacije riješiti i nekom konvencionalnom metodom, vrlo često se koriste za promociju neizrazitog koncepta i ilustraciju činjenice da za uspješnu regulaciju nije potrebno poznavanje diferencijalnih jednadžbi modela [55-57].

2.2.2 Nadređene regulacijske strukture.

U ovom su paragrafu opisani najčešći načini primjene neizrazitih modela u nadređenim regulacijskim strukturama gdje se koriste ili za formiranje regulacijskih signala ili za adaptaciju strukture i parametara konvencionalnih i neizrazitih regulatora.

Kaskadna regulacija

Kvaliteta djelovanja jednostrukog regulacijskog kruga može se poboljšati proširivanjem na sustav kaskadne regulacije u kojem se razlikuju glavni i pomoćni regulator (ili nadređeni i podređeni regulator). Ilustracija kaskadne regulacije data je na slici 2.13. Glavni, neizraziti regulator (*NR*) regulira glavni proces (P_2), a određuje zadane vrijednosti pomoćnog regulatora (R_1) koji može biti ili neizrazit ili konvencionalan (kada je riječ o tzv. hibridnoj izvedbi) i koji regulira podređeni proces (P_1).

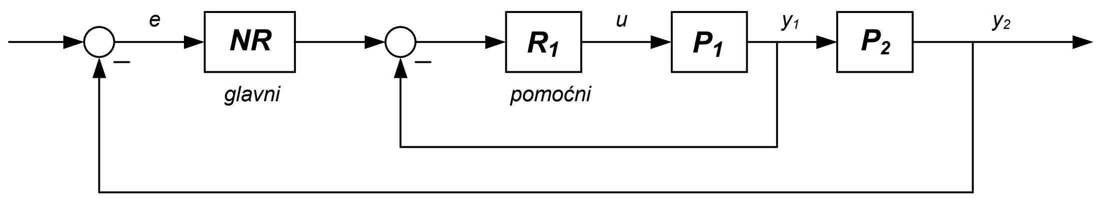

Slika 2.13 Shema neizrazite kaskadne regulacije

Glavni regulator ne mora nužno regulirati samo jednu varijablu već npr. neizrazita pravila mogu odlučivati koja će od dvije regulirane varijable biti u akciji i osigurati bezudarni prijelaz s jedne na drugu. Takav primjer biranja između regulacije brzine ili regulacije udaljenosti u vožnji automobila opisan je u [58].

Međutim broj reguliranih varijabli kao i broj podređenih regulatora može biti i puno veći. Prema [13] stvarni potencijal za primjenu neizrazite logike u industrijskoj automatizaciji leži u mogućnosti izravnog projektiranja multivarijabilnih regulatora. U mnogim industrijskim primjenama PID regulatori kvalitetno održavaju pojedinačne procesne varijable na zadanim vrijednostima koje u mnogim slučajevima operateri zadaju ručno na temelju analize uvjeta odvijanja procesa i kriterija optimizacije. PID regulator je predviđen za obradu samo jedne ulazne varijable. U situacijama s više reguliranih varijabli koristi se nekoliko odvojenih regulacijskih krugova. Ukoliko se međuovisnosti između reguliranih procesa žele iskoristiti potrebno je zadane vrijednosti lokalnih regulacijskih krugova voditi uz pomoć matematičkog modela.

Modeliranje realnih industrijskih procesa je zahtjevno i dugotrajno, a većina modela uvodi i pojednostavljenja koja mogu degradirati kvalitetu regulacije. Također relativno malo ljudi ima znanje potrebno za rigorozno matematičko modeliranje, pa je stoga uobičajena situacija u industriji da su pojedine procesne varijable regulirane s jednostavnim regulacijskim modelima, dok nadređenu regulaciju provodi operater. U takvim situacijama korištenjem neizrazite logike moguće je projektirati nadređene i viševarijabilne regulatore na temelju iskustva operatera. Primjeri primjene viševarijabilnih nadređenih neizrazitih regulatora u regulaciji temperature izgaranja u pećima za spaljivanje otpada i regulaciji postupka odvajanja fosfata iz otpadnih voda opisani su u [59, 60].

Neizrazita adaptivna regulacija

Prema definiciji [61] adaptivni regulacijski sustavi mogu prilagoditi akcije regulatora promjenjivim dinamičkim i statičkim svojstvima reguliranog procesa. Većina adaptivnih regulatora dijeli se na dvije grupe: unaprijedne i s povratnom vezom. Unaprijedni adaptivni regulatori (slika 2.14) koriste se u regulaciji procesa čija se promjenjiva svojstva mogu procijeniti na temelju odabranog signala (v). Uz poznata pravila prilagodbe parametara (Π) regulatora moguće je realizirati i neizrazitu adaptaciju kakva je npr. prikazana Sugeno modelom na slici 2.9.

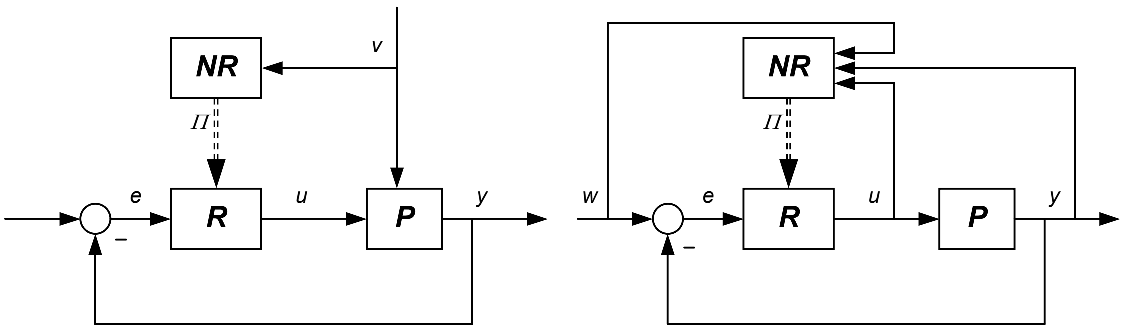

Slika 2.14 Unaprijedna adaptacija

Slika 2.15 Adaptacija u povratnoj vezi

Ako se ponašanje procesa ne može odrediti izravno na temelju mjerenja vanjskih procesnih signala tada se primjenjuje adaptacija regulatora u povratnoj vezi koja je prikazana na slici 2.15. Svojstva procesa koja se mijenjaju određuju se s pomoću mjerenja različitih regulacijskih signala u unutrašnjim krugovima.

Klasična adaptivna regulacija s povratnom vezom temelji se ili na identifikaciji parametara matematičkog modela procesa ili usporedbi procesnih signala sa signalima iz referentnog modela. Prema [62] prvi slučaj naziva se i neizravna adaptacija, jer se parametri regulatora korigiraju na temelju prethodno određenih parametara procesa, dok drugi slučaj, zbog neposrednog definiranja korekcija u funkciji odstupanja od referentnog stanja, predstavlja izravnu adaptaciju.

Kod neizrazite adaptacije u povratnoj vezi, umjesto matematičkog modela procesa koriste se pravila adaptacije koja se temelje na mjerenjima signala zatvorenih regulacijskih krugova. Npr. vrijednosti signala *u*, *y*, *w* definiraju trenutnu kvalitetu regulacije na osnovu koje se u neizrazitom regulatoru (*NR*) određuje potrebna korekcija parametara. Znanje eksperta može se iskoristiti i za modeliranje procesa uz pomoć neizrazitih pravila. Različite primjene neizrazitog modela u adaptivnim regulatorima opisane su u radovima [63 - 67].

Neizrazito ugađanje parametara regulatora

Ovaj oblik primjene neizrazitih modela u nadređenoj regulacijskoj strukturi u osnovi ne predviđa promjenu dinamičkih i statičkih svojstava reguliranog procesa. U radovima [68, 69] opisane su relativno jednostavne primjene ugađanja parametara klasičnih regulatora preko neizrazitih pravila. Analiziraju se uzastopni odzivi zatvorenog kruga na nagle promjene referentne veličine i kao ulazne varijable u neizraziti sustav koriste: nadvišenje, trenutak postizanja 90% zadane vrijednosti, početak stacioniranja, ili samo regulacijsko odstupanje. Početne vrijednosti parametara su male, a tipično pravilo ugađanja, npr. PI regulatora glasi: AKO je nadvišenje *malo* i vrijeme približavanja zadanoj vrijednosti *u redu* ONDA povećaj vrijednost pojačanja za 30%. Na sličan način kao što bi to radio i iskusan operater, neizraziti modul zaključuje koje parametere treba promijeniti u svrhu poboljšanja kvalitete regulacije.

Ukoliko se u podređenom krugu nalazi neizraziti regulator problem ugađanja parametara postaje znatno složeniji. Problem izbora strukture, broja i oblika funkcija pripadnosti predmet je brojnih istraživanja još od vremena prvih praktičnih primjena. Detaljniji prikaz problema dat je u poglavlju 2.3.

Neizrazita regulacija procesa u posebnim pogonskim uvjetima

U normalnim pogonskim uvjetima kvaliteta regulacije većine procesa može se dovesti na zadovoljavajuću razinu (u smislu stabilnosti i brzine uklanjanja regulacijskog odstupanja) već s fiksnim parametrima regulatora ili s adaptivnim regulatorom (najčešće s unaprijednom adaptacijom parametara). To je npr. slučaj s regulacijom protoka ili tlaka u izmjenjivačima topline ili parnim kotlovima unutar raspona 30 - 100% opterećenja. Kod nižih opterećenja pogon s običnim regulatorima često puta nije moguć zbog činjenice da se dinamičke i statičke značajke regulacijske staze znatno izmjene.

Otežana regulacija procesa pojavljuje se: u fazama pokretanja ili obustave (motora, strojeva ili industrijskih procesa), kod ispada procesa, kod naglog kočenja vozila (velika proklizavanja, blokiranje kotača)… U takvim slučajevima ponašanje procesa često puta nije dovoljno poznato budući da neki fizikalni zakoni nisu više važeći ili nisu poznati. Uobičajen način vođenja takvih procesa ručno vođenje od strane iskusnog operatera koji vraća proces u normalno pogonsko stanje. Moguće je i projektiranje posebnih neizrazitih regulatora koji koriste pravila prikupljena od operatera. Opis primjena u proizvodnji praška za pranje i upravljanju destilacijskom kolonom dat je u [70, 71].

2.2.3 Razina vođenja procesa

Na razini vođenja procesa dominira kvalitativno znanje izraženo u obliku intuicije i iskustva operatera koji na temelju raspoloživih informacija o trenutnom stanju i postavljenih zahtjeva odlučuje o načinu vođenja procesa. Premda je obrada kvalitativnog znanja i neodređenosti po definiciji područje glavne primjene neizrazite logike gotovo da i nema praktičnih aplikacija. Moguća primjena opisana je u glavi 4., gdje je pokazano kako se neizrazita logika može iskoristiti za optimizaciju pogonskih troškova u dnevnom pogonu termoenergetskog bloka.

2.2.4. Stabilnost

Pojam stabilnosti u uskoj je vezi s pojmom regulacije. U području primjena neizrazite logike se po pitanju stabilnosti razlikuju dvije grupe autora. Prvi, i brojniji, koji analizu stabilnosti zanemaruju te simulacijama i prototipima dokazuju kvalitetu implementiranog koncepta, te drugi koji neizrazite regulatore pokušavaju svesti u okvire unutar kojih se ta analiza može provesti. Glavni problem analize stabilnosti predstavlja složena struktura i nelinearna karakteristika neizrazitog regulatora. Ako se proces ne može modelirati matematički, tada se analitički dokazi stabilnosti ne mogu napraviti. Metode ispitivanja stabilnosti uglavnom su preuzete iz teorije nelinearnih regulacijskih sustava (npr. metoda Ljapunova), a opisane su u [72-74].

2.3 ODREĐIVANJE STRUKTURE I PARAMETARA NEIZRAZITOG MODELA

U ranim radovima koji su opisivali primjene neizrazite logike u regulacijskim sustavima isticana je, kao jedna od glavnih prednosti neizrazitog u odnosu na konvencionalni regulator, mogućnost brze i relativno jednostavne izrade prototipa neizrazitog regulatora bez korištenja matematičkog modela procesa. Međutim, već su primjene na malo složenijim procesima pokazale da su izbor strukture i postupak finog ugađanja zahtjevni projektni zadaci. Rješavanje tih zadataka evoluiralo je od u prošlosti raširenog iskustvenog pristupa (utemeljenog na tzv. inženjerskoj metodi pokušaja i pogrešaka), do danas prevladavajućih automatiziranih algoritama u kojima se koriste složene matematičke metode optimiranja multivarijabilnih sustava.

2.3.1. Iskustveni pristup

Neizraziti model definira neizrazito statičko preslikavanje na čiji izgled, kao što je pokazano u prethodnim razmatranjima, utječu brojni faktori: ulazna i izlazna pojačanja, broj, oblik i raspodjela funkcija pripadnosti, tip neizrazito-izrazite pretvorbe, te izbor algoritma zaključivanja. Iskustveni pristup u ugađanja slijedi opće preporuke tipa:

– broj funkcija pripadnosti ulaznih varijabli je 7,
– približno logaritamska raspodjela težišta daje finiju podjelu intervala ulaznog signala u području malih vrijednosti,
– trapezni oblik funkcija pripadnosti osiguravaju nepromjenjljivost izlaznog signala u određenim intervalima promjene ulaznih,

a preostali parametri se ugađaju u cilju dobivanja željene kvalitete regulacije ili zahtijevanog oblika statičkog preslikavanja.

Utjecaj oblika i raspodjele funkcija pripadnosti izlazne varijable istražen je u [75] na primjeru modela s dvije ulazne varijable, jednoliko raspodijeljenim trokutnim funkcijama pripadnosti te metodom težišta u neizrazito izrazitoj pretvorbi. Analiza je pokazala da najveći utjecaj ima raspodjela težišta funkcija pripadnosti dok su oblik i širina funkcija kao i metode zaključivanja (max-min ili max-prod) od minornog značaja i utječu samo na način interpolacije izlazne funkcije između težišta. Također širina pravokutnika i trokuta nema utjecaja, sve dok funkcije pripadnosti ne prekrivaju jedna drugu. Prekrivanje trokuta daje glatke nelinearne značajke. Korištenje singletona značajno smanjuje vrijeme računanja izlazne vrijednosti. Izrazite nelinearne karakteristike dobijaju se uglavnom s nejednolikom raspodjelom težišta izlaznih funkcija.

Nešto grublja analiza utjecaja pojedinih parametara neizrazitog modela određuje prioritete u algoritmu automatskog ugađanja parametara [76]:

- izlazna pojačanja (npr. K_p na slici 2.11.) imaju izravan utjecaj na ukupno pojačanje regulatora, pa tako i na stabilnost cjelokupnog sustava i kod optimiranja im se pridaje najveći značaj [77],
- promjena ulaznih pojačanja (K_e i K_{de} na slici 2.11) utječe na osjetljivost regulatora koja je povezana s najpovoljnijim izborom područja ulaznog signala; ulazna pojačanja nisu presudna za ukupnu kvalitetu odziva reguliranog sustava i tijekom optimiranja izlaznih pojačanja ne mijenjaju vrijednost.
- ugađanje oblika funkcija pripadnosti te traženje optimalne raspodjele njihovih težišta (kako ulaznih tako i izlaznih signala) spada u postupke finog ugađanja; sustav se ne može dovesti u nestabilno stanje promjenom funkcija pripadnosti.

Slične preporuke, samo u drukčijem redoslijedu, koriste se i u [78]. Polazi se od linearnog neizrazitog regulatora koji je ekvivalent konvencionalnom, zatim se promjenom oblika funkcija pripadnosti formira nelinearna statička funkcija i na kraju se korigiraju izlazna i ulazna pojačanja.

2.3.2. Algoritmi određivanja parametara i strukture neizrazitog sustava

Određivanje parametara regulatora

Još u vrijeme prvih praktičnih primjena neizrazite logike u regulaciji procesa predložen je koncept neizrazitog samoorganiziraućeg regulatora *(fuzzy **s**elf-**o**rganizing **c**ontroller - SOC)* kao prvi pokušaj algoritmiziranja postupka ugađanja parametara neizrazitog modela [79]. Premda je u to vrijeme još postojala razlika u tumačenju pojmova samoorganizirajuće (ili samougađajuće) i adaptivno, danas se SOC svrstava u grupu adaptivnih regulatora, dakle regulatora s ugodivim parametrima i pripadnim mehanizmom ugađanja. Struktura SOC-a je hijerarhijska, u kojoj se na nižoj razini nalazi regulator zadan u obliku tablice, a na višoj razini nalazi se mehanizam adaptacije. Tablično zadavanje nelinearne statičke karakteristike neizrazitog regulatora, pogoduje praktičnim primjenama jer se umjesto složenog proračuna algoritma zaključivanja (izrazi 2.15 - 2.17) izlazna varijabla određuje interpolacijom elemenata tablice. Korigiranje parametara u tablici provodi se u seriji uzastopnih simulacija (ili eksperimenata na objektu) u kojima se u sustav uvodi odabrani premećaj. Mehanizam adaptacije modificira vrijednosti elemenata u tablici na temelju trenutne mjere performanse sustava (određene usporedbom procesnih signala i signala iz referentnog modela kojim je definirano željeno ponašanje sustava). Prema [80], postupci ugađanja neizrazitog samorganizirajućeg regulatora osiguravaju lokalni optimum (u smislu optimalnog odziva na karakteristični oblik poremećajne funkcije), te eventualno globalni optimum (ukoliko na regulirani proces slabije utječu ili uopće ne djeluju drugi poremećajni signali). S vremenom je izvorni koncept SOC-a evoluirao u različite oblike adaptivnih neizrazitih regulatora iako se izvorni naziv i dalje susreće u radovima [81-83].

Jedno je od obilježja neizrazitih adaptivnih regulatora da se sve manje koriste pojedine elemente izvornog koncepta neizrazitog sustava. Uz već spomenuti tablični model, u nekim se primjerima postavljaju uvjeti na oblik funkcija pripadnosti ili na raspodjelu njihovih težišta. Kod adaptacije neizrazitih regulatora koji koriste standardnu bazu pravila, broj pravila najčešće je određen produktom broja funkcija pripadnosti zadanih nad ulaznim varijablama, što kod većeg broja ulaznih varijabli značajno usporava numeričku proceduru adaptacije. U [84] opisana je mogućnost sinteze neizrazitog adaptivnog regulatora bez korištenja baze pravila s drastičnom redukcijom broja slobodnih parametara (na primjeru s 3 ulazne varijable, svaka sa po 10 funkcija pripadnosti, odnos izvornog i predloženog koncepta je 1000 prema 45).

Određivanje parametara neizrazitog modela procesa (neuro-fuzzy modelling)

Uz već spomenutu mogućnost korištenja u mehanizmima adaptacije (kako konvencionalnih tako i neizrazitih regulatora) neizraziti modeli reguliranog procesa mogu imati i značajniju ulogu u regulacijskom sustavu. Načelno se razlikuju dva tipa primjene: neizrazita inverzna regulacija, i korištenje neizrazitog modela za procjenu budućeg dinamičkog odziva sustava u sklopu tzv. *fuzzy model-based predictive control*. Kvaliteta regulacije u oba slučaja ovisi o točnosti neizrazitog modela procesa. Primjeri primjene i moguće konfiguracije sustava dati su u [36, 85].

Način definiranja neizrazitog modela u mnogome ovisi o količini i raspoloživosti prethodnog znanja o procesu. Razlikuju se dva pristupa:

1. Struktura modela prethodno je određena skupom jezičnih pravila formuliranih od strane eksperta. Parametri u strukturi mogu se fino ugađati korištenjem dostupnih ulazno-izlaznih podataka o procesu. Neki algoritmi finog ugađanja koriste činjenicu da je na računskoj razini neizraziti model slojevita struktura slična neuronskoj mreži pa se koriste već standardni algoritmi učenja (tzv*. neuro-fuzzy modelling*)
2. Ukoliko ne postoji prethodno znanje o procesu, neizraziti model se konstruira samo na temelju ulazno-izlaznih podataka, uz očekivanje da će izvedena pravila omogućiti naknadnu interpretaciju ponašanja sistema. Koriste se tzv. *fuzzy – clustering* tehnike.

Mogućnost prikaza neizrazitog modela u obliku neuronske mreže rašireno se koristi u postupcima automatskog određivanja parametara neizrazitog modela na temelju raspoloživih ulazno izlaznih podataka. Prema definiciji datoj u [86] *neuro-fuzzy* model je poseban oblik troslojne unaprijedne neuronske mreže u kojoj se umjesto aktivacijskih funkcija koriste *T*–norme i *S*-konorme. Prvi sloj predstavlja ulazne varijable, srednji (skriveni) sloj predstavlja neizrazita pravila, a treći sloj predstavlja izlazne varijable. Neizraziti skupovi definirani su u obliku težinskih veza između čvorova. Premda neki modeli koriste više od tri sloja i neizrazite skupove prikazuju kao aktivacijske funkcije, uobičajeno je moguće i te modele transformirati u troslojnu arhitekturu.

Primjer neizrazitog modela strukturiranog u obliku neizrazite mreže dat je na slici 2.16. Unutrašnji čvorovi R_1, R_2, … R_5, predstavljaju pravila, čvorovi ξ_1, ξ_2 i η, ulazne i izlazne varijable, a $\mu_r^{(i)}$ i ν_r neizrazite skupove jezičnih varijabli premisa i zaključka $A_r^{(i)}$ i B_r. Pravila koja imaju iste premise koriste tzv. zajedničke težine, prikazane elipsama. Čvor R_1 predstavlja pravilo oblika AKO ξ_1 je $A_1^{(1)}$ I ξ_2 je $A_1^{(2)}$ ONDA η je B_1 . Struktura modela omogućava učenje i optimiranje baze pravila Mamdani modela.

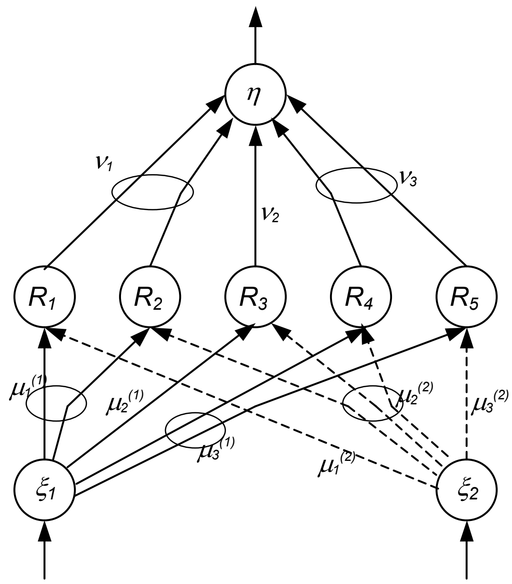

Slika 2.16. Neuro-fuzzy model

Opisana struktura implementirana je programskom paketu NEFCON [87], a poznati su još: ANFIS [88], FuNe [89], Fuzzy RuleNet [90], GARIC [91]. Paket ANFIS isključivo se koristi za identifikaciju parametara u unaprijed definiranoj strukturi, dok NEFCON može odrediti početnu arhitekturu sustava prije procedure ugađanja parametara.

Izbor glatkih funkcija pripadnosti omogućava primjenu gradijentnih tehnika učenja (razvijenih u području neuronskih mreža, [35]) i fino ugađanje modela na temelju raspoloživih podataka. Jedna od glavnih prednosti neuro-fuzzy sustava je transparentnost, odnosno mogućnost interpretacije modela preko skupa jezičnih (neizrazitih) pravila. Međutim, zahtjev za većom točnosti može smanjiti transparentnost modela. Ako modifikacije parametara nisu ograničene (semantičkim svojstvima neizrazitog sustava) obično dolazi do povećanja stupnja preklapanja funkcija pripadnosti, a moguća je situacija i da jedna funkcija pripadnosti bude obuhvaćena drugom ili da funkcije pripadnosti zamijene mjesta. Ova razmatranja iznesena su u [92] u širem kontekstu usporedbe i evaluacije različitih tehnika koje se osim za određivanje parametara koriste i za identifikaciju strukture neizrazitih modela.

Određivanje strukture neizrazitog modela procesa

Identifikacija strukture neizrazitog modela na temelju raspoloživog skupa ulazno-izlaznih podataka obuhvaća sljedeće korake:

– selektiranje relevantnih ulaznih varijabli,
– određivanje inicijalne arhitekture (particija ulaznog prostora, broj funkcija pripadnosti za svaki ulaz, broj neizrazitih pravila, određivanje premise i određivanje zaključka),
– izbor inicijalnih parametara za funkcije pripadnosti.

U [92] razmotrena su tri pristupa, koji na različite načine rješavaju problem aproksimacije funkcije, zadane točkama u prostoru ulazno izlaznih varijabli, neizrazitim modelom. U tehnici tzv. *fixed grid partitioning* nad domenama ulaznih i izlaznih varijabli unaprijed se specificira broj i uniformna raspodjela funkcija pripadnosti. Baza pravila postavlja se tako da pokrije ulazni prostor. Korištenjem raspoloživih podataka određuje se stupanj vrijednosti pravila, a parametri zaključka se procjenjuju korištenjem metode najmanjih kvadrata. Nedostatak ove tehnike je veliki broj pravila U tehnici grananja, ili tzv. *tree search partitioning* prostor ulaznih varijabli dijeli se na unaprijed definiran broj hiperpravokutnika. Algoritam CART [93] ilustriran je na slici 2.17 [35] na primjeru aproksimacije trodimenzijske funkcije. Kvaliteta aproksimacije (točnost lokalnih modela) proporcionalna je broju prethodno definiranih polja (pravila). Stoga, broj pravila raste s porastom točnosti aproksimacije.

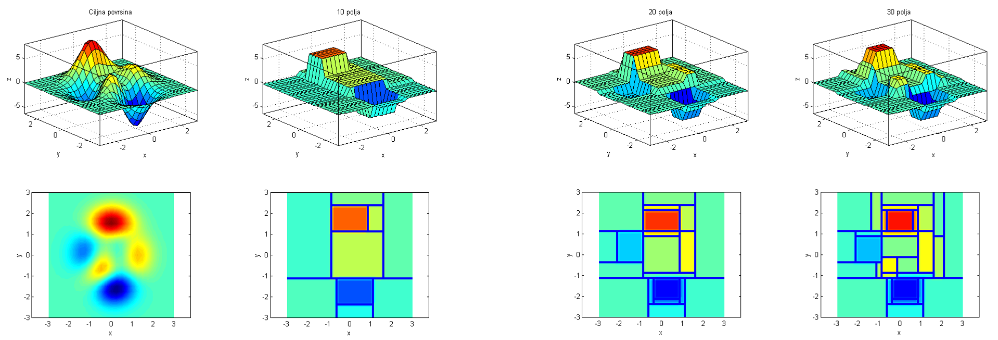

Slika 2.17. Ilustracija CART algoritma, u stupcima su redom prikazani: polazna funkcija, aproksimacija s 10, s 20 i s 30 polja u domeni ulaznh varijabli

Tehnika neizrazitog grupiranja, tzv. *fuzzy clustering* [94], primjenjuje se za otkrivanje područja u prostoru ulazno-izlaznih varijabli u kojima se sustav može lokalno aproksimiratri. Unaprijed definirani broj grupa (klastera) određuje broj pravila u neizrazitom modelu. Točke u ulazno izlaznom prostoru povezane su s klasterom kod kojeg imaju najveću pripadnost. Svaki klaster predstavlja neizrazito ako - onda pravilo i može se gledati kao višedimenzijski neizraziti skup. Neizraziti skupovi u premisi dobivaju se projekcijom klastera na domene ulaznih i izlaznih varijabli i aproksimiraju s odgovarajućim parametarskim funkcijama.

2.4 ZAKLJUČNA RAZMATRANJA (pro & contra primjene neizrazite logike u regulacijskim sustavima)

Unatoč brojnim industrijskim realizacijama i višegodišnjim istraživanjima, još uvijek su aktualne rasprave o opravdanosti primjene neizrazite logike u sustavima regulacije i vođenja. Nepomirljivost stavova zagovornika i protivnika koncepta dobro ilustrira debata koju su vodili eminentni istraživači M. Athans i L. Zadeh na temu Fuzzy Control vs. Conventional Control na konferenciji EUFIT99 (7^{th} European Congress on Intelligent Techniques and Soft Computing, Aachen, Germany, 13.-16.09.1999), a koja je objavljena u [95].

Protivnici

Prof. Athans i drugi kritičari primjene neizrazite logike u regulacijskim sustavima uglavnom nastoje dokazati inferiornost koncepta neizrazitog regulatora u odnosu na klasične regulacijske tehnike. Njihovi stavovi sažeti su u nastavku.

Za bilo koji standardni regulacijski problem, klasični regulator uvijek može nadmašiti neizraziti, ali uz uvjet korištenja sofisticiranih metoda projektiranja koje pretpostavljaju poznavanje nelinearnog modela procesa. Nelinearni model potreban je za izvođenje lineariziranih modela za različita pogonska stanja, u kojima se određuju parametri lokalnih linearnih regulatora (kompenzatora). Vođenjem parametara osigurava se kvalitetna regulacija (prema točno propisanim kriterijima stabilnosti i zahtjevima na performansu) globalne nelinearne staze.

Nasuprot klasičnoj, ili normativnoj, neizrazita regulacija je empirijska, ili deskriptivna, osobito kada je u pitanju prva generacija neizrazitih regulatora. Mamdani model polazi od skupa diskretnih upravljačkih pravila koje interpolira u sustav korištenjem funkcija pripadnosti uvedenih u teoriji neizrazitih skupova. U sintezi neizrazitog regulatora imitira se ponašanje čovjeka, ne postoji eksplicitna deklaracija kvalitete regulacije, nema kvantitativnog dinamičkog modela staze, nema garancije robusnosti s obzirom na stabilnost niti s obzirom na performansu. Premisa da je čovjek dobar regulator, ne vrijedi za složene i viševarijabilne sustave. Također, pitanje je u kojoj mjeri čovjek može predvidjeti sve moguće situacije koje mogu nastupiti uslijed poremećaja, pojave mjernog šuma ili varijacije parametara staze, kao i probleme koji mogu nastati zbog nestabilnosti. Zaključuje se da Mamdani modeli mogu biti pogodni samo za jednostavne regulacijske probleme koji ne zahtijevaju visoku točnost, niti garanciju stabilnosti.

Niti druga generacija neizrazitih regulatora (Tagaki - Sugeno), premda ciljano razvijena, nije uspjela stišati kritike koje se odnose na garanciju stabilnosti, što u novijim radovima priznaju i sami istraživači [96-101]. Sugeno model aproksimira globalnu nelinearnu dinamiku interpolacijom lokalnih modela koristeći funkcije pripadnosti. Lokalni regulatori projektiraju se korištenjem izrazitih metoda (iz teorije optimalnog upravljanja), a parametri se interpoliraju preko funkcija pripadnosti (što je prema Athansu inferiorno klasičnoj, "gain-scheduling" tehnici). Za provedbu analize stabilnosti nužno je postojanje matematičkog modela, a koriste se alati iz klasične teorije. Stoga Athans postavlja pitanje: "Ako je jasno da je model u prostoru stanja nužan, zašto uvoditi neizrazite ideje kada se problem može izravno riješiti klasičnim metodama?".

Velika popularnost neizrazite regulacije posljedica je (prema Athansu) činjenice da je vrijeme potrebno za njeno razumijevanje za red velične manje od vremena potrebnog za učenje klasičnih koncepata (diferencijalnih jednadžbi, linearne algebre, teorije stabilnosti, metoda prostora stanja, teorije optimalnog upravljanja, ...).

Uspješne primjene neizrazitog regulatora u proizvodima široke potrošnje (klima-uređaji, kamere, perilice,...) Athans objašnjava ugradnjom dodatnih osjetnika i izvršnih organa, te zatvaranju povratne veze, a u tim uvjetima bi i konvencionalni regulatori postigli ekvivalentnu performansu.

Zagovornici

Stavovi prof. Zadeha, nisu izravni odgovori na upućene kritike već pokušaj isticanja dobro poznatih prednosti koncepta neizrazitog regulatora.

Neizraziti regulator nije zamjena, nego dopuna i proširenje tradicionalnih regulacijskih metodologija. Osobito je pogodan za rješavanje problema koji se teško mogu modelirati kao i za probleme gdje zadaća regulacije nije eksplicitno (izrazito) definirana (kao npr. kod vožnje automobila).

Po pitanju stabilnosti često se citira stav Mamdaniev stav [102]: "Za provedbu analize stabilnosti nužan je točan matematički model regulirane staze, što je prezahtjevan uvjet kada su pitanju složeni industrijski (industrija cementa ili čelika) ili ekonomski procesi, čiju dinamiku definira ljudsko ponašanje. Industrija nije nikad isticala da je matematička analiza stabilnosti nužan i dovoljan uvjet za prihvaćanje regulacijskog sustava. To je samo pogled koji znanstvenici u području regulacije žele staviti u prvi plan, ali taj pogled nije prihvaćen nigdje izvan akademskih krugova. Ispitivanje prototipova je puno značajnije nego analiza stabilnosti. To je dobro iskušan i ispitan industrijski pristup i nema razloga da ne bude dovoljan u regulacijskim sustavima."

Prilično neakademska opravdanja relativno kasne primjene koncepta neizrazitog regulatora zagovornici nalaze u dugogodišnjoj dominaciji analitičkih metoda prekinutoj s ekspanzijom primjena u Japanu. Prema Zadehu: "Američka kultura utemeljena na ideji prodaje prihvatila je neizrazitu logiku tek kad je u Japanu dokazano da postoji tržište za takve proizvode."

Perspektivu neizrazitog koncepta zagovornici vide u aproksimaciji pravila u složenim sustavima odlučivanja. Aproksimativno zaključivanje pruža metodu za modeliranje ljudske klasifikacije i rezoniranja, uključivo i govorni jezik i razumijevanje. Iako je napravljeno puno istraživanja razlog malog broja aplikacija je u procesorskim i memorijskim ograničnjima postojeće generacije računala.

Neizraziti regulator je samo mali dio puno šireg okvira teorije aproksimativnog zaključivanja, s tri karakterisitična skupa pravila: 1) skup koji osigurava brzi odziv na veliko regulacijsko odstupanje, 2) skup koji sprječava nadivšenje i 3) skup za održavanje regulacijskog odstupanja blizu nulte vrijednosti. Ovakva kategorizacija pravila može biti razumljivija krajnjem korisniku i preferirana od strane projektanta, i u slučajevima za koje postoji mogućnost primjene konvencionalnih metoda. Također, Zadeh predviđa da će postupci i metode projektiranja nelinearne regulacijske funkcije opstati makar i pod novim imenom.

Tko je u pravu?

Na ovo pitanje moguće je dati samo neizrazit odgovor: "Jedni i drugi, do neke mjere." Skroman doprinos usporedbi koncepata dat je i u ovoj tezi.